머신러닝
지도학습

Machine Learning
Supervisor learning

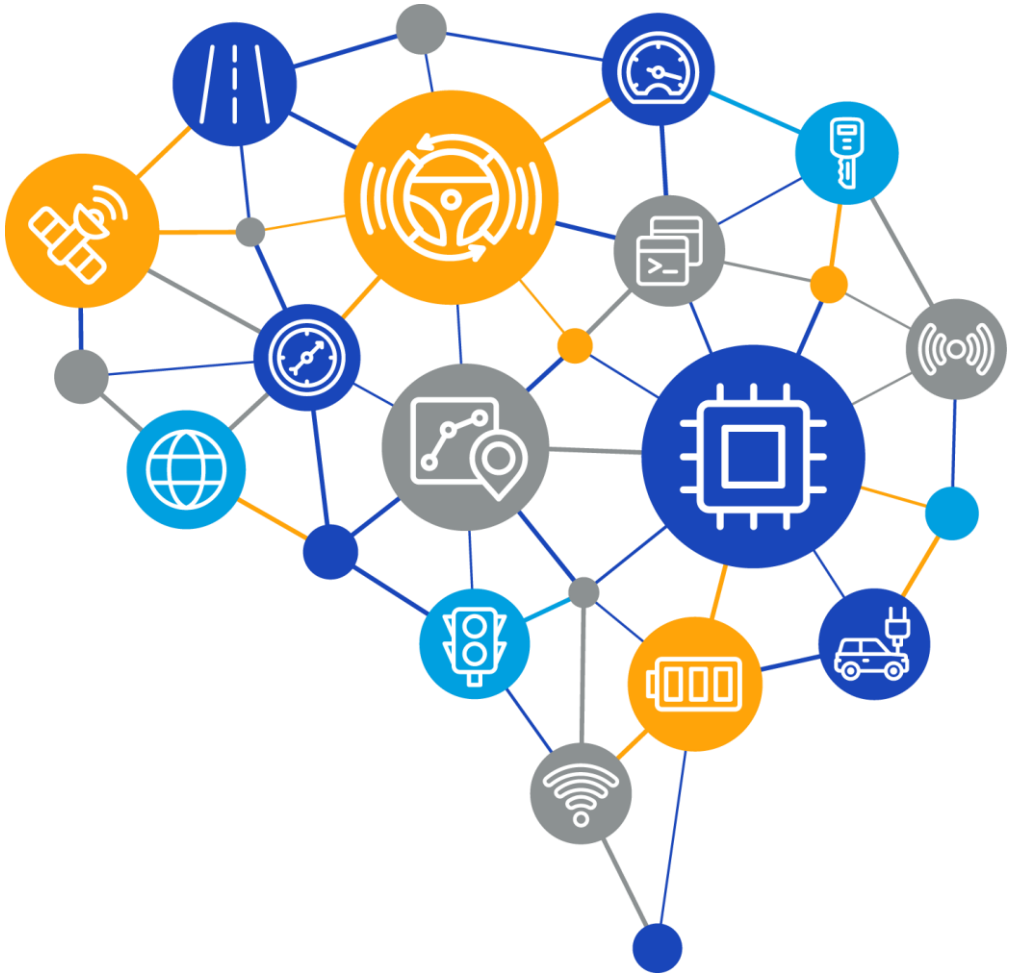

2022.05

강환수 교수

DMUAi 동양미래대학교
인공지능소프트웨어학과

AI Experts Who Lead
The Future

AI Experts
Who Lead
The Future

CONTENTS

AI Experts
Who Lead
The Future

01

머신러닝이란?

다음 자료를 기반으로 제작
난생처음 인공지능 입문 (출판사: 한빛아카데미)

01. 머신러닝이란?

- 인공지능, 머신러닝, 딥러닝의 관계

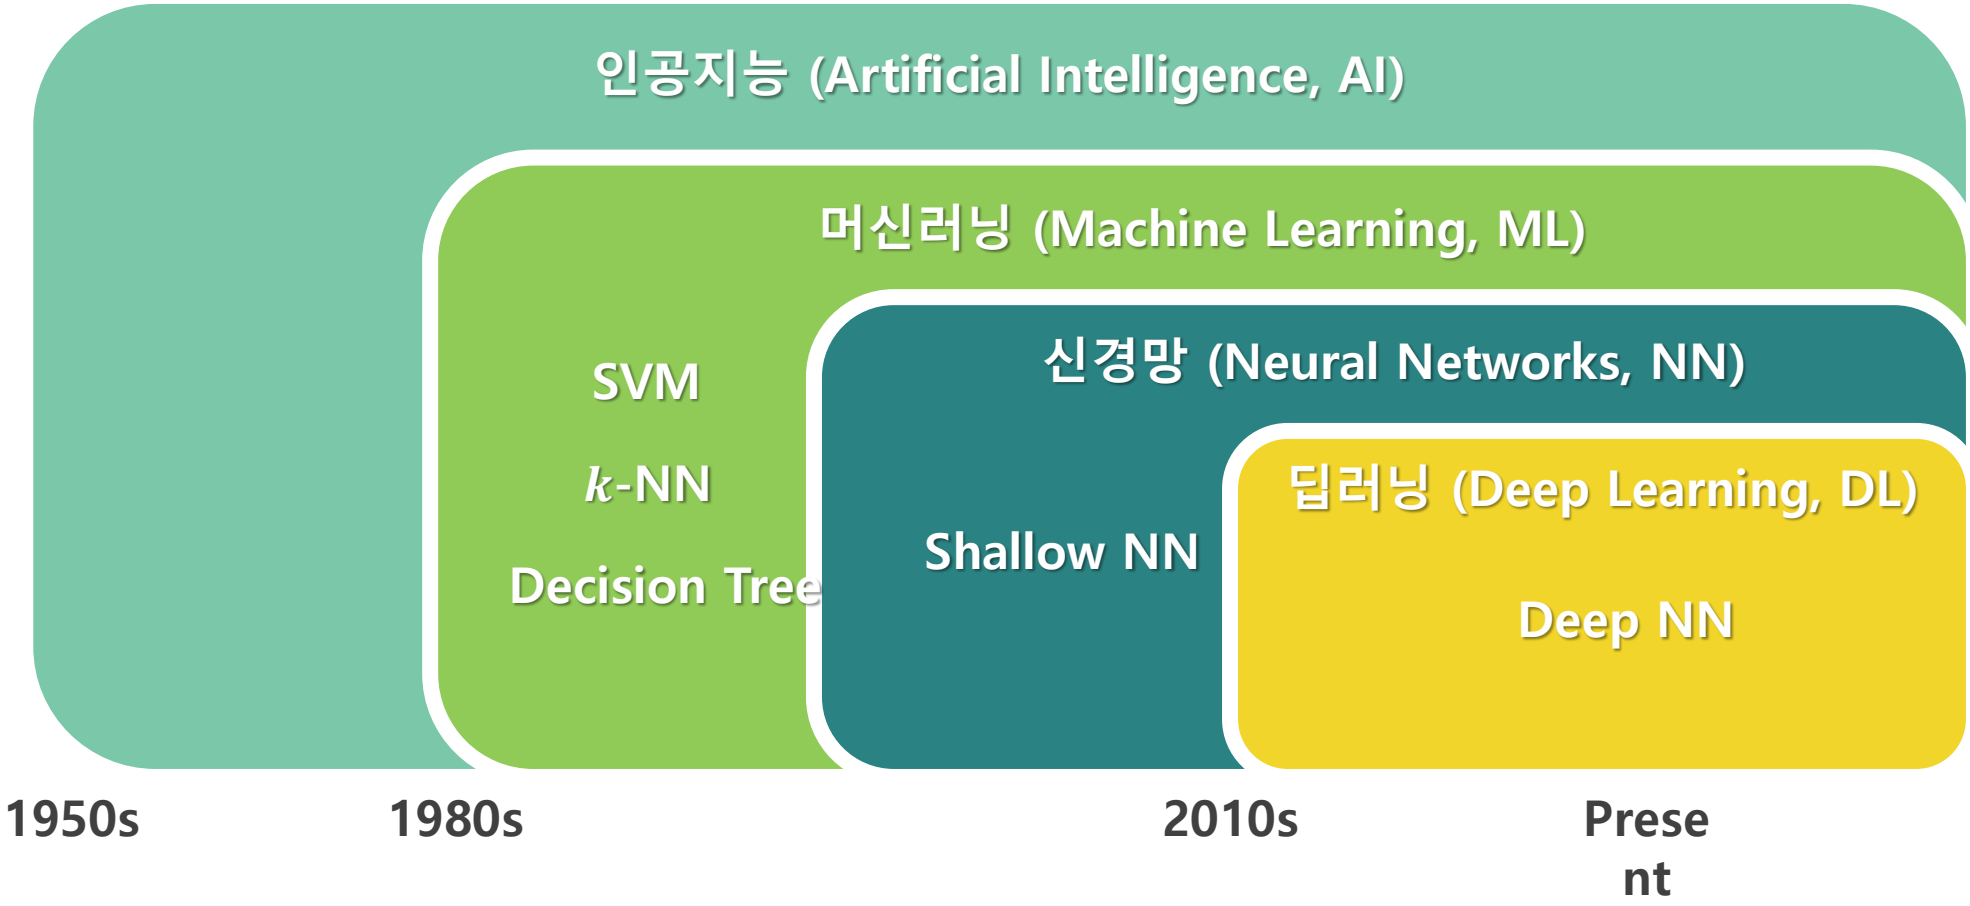

01. 머신러닝이란?

- **머신러닝의 개념 (1/5)**
  - 머신러닝 (Machine Learning, ML)
    - 컴퓨터가 명시적으로 프로그램 되지 않고도 학습할 수 있도록 하는 연구 분야를 말함
    - 용어는 1959년에 아서 사무엘이 학술지 <IBM Journal of Research and Development>에 기고한 논문에서 처음 사용함

[사진출처] https://en.wikipedia.org/wiki/Arthur_Samuel

아서 사무엘의 머신러닝 정의

"머신러닝은 컴퓨터가 명시적으로 프로그램되지 않고도 학습할 수 있도록 하는 연구 분야를 말합니다."

(Machine Learning is the field of study that gives computers the ability to learn without being explicitly programmed.)

01. 머신러닝이란?

- **머신러닝의 개념 (2/5)**
  - 일반적인 프로그래밍 작업
    - 입력값에 따라 원하는 결과값이 출력되도록 사람이 내부 동작을 작성
  - 머신러닝
    - 사람이 컴퓨터에게 입력값과 결과값만 충분히 전달해 주면
      컴퓨터가 스스로 입력값과 결과값의 관계를 만족시키는 내부 동작을 찾아냄
      - 학습 데이터 (훈련 데이터, Training Data): 내부 동작을 만들 때 사용한 데이터 (입력값과 결과값)
      - 시험 데이터 (Test Data): 만들어진 내부 동작의 성능을 평가할 때 사용하는 데이터

01. 머신러닝이란?

- **머신러닝의 개념 (3/5)**
  - 머신러닝은 여러 개의 입력값과 결과값을 컴퓨터에 제공하기만 하면 이 데이터를 바탕으로 컴퓨터가 스스로 내부 동작을 만들어 냄
  - 이를 위해서 사람은 양질의 많은 학습 데이터를 공급해야 함

그림 2-2 일반적인 프로그래밍 방식과 머신러닝 방식 비교

01. 머신러닝이란?

- **머신러닝의 개념 (4/5)**
  - 인공지능 시대의 소프트웨어 역량
    - 머신러닝 방식에서 우수한 개발자란 데이터에 대한 통찰력과 수집 능력이 우수하여 머신러닝 기계에 양질의 학습 데이터를 충분히 공급할 수 있는 사람임
    - 일반적인 프로그래밍 방식에서 우수한 개발자란 논리적인 사고를 통해 프로그래밍 언어를 자유자재로 사용할 수 있는 사람이었음
    - 앞으로는 쓸모 있는 데이터를 누가 더 많이 보유하고 있느냐에 따라 소프트웨어 역량이 결정될 것

01. 머신러닝이란?

- **머신러닝의 개념 (5/5)**
  - 카네기 멜론 대학교 교수인 톰 미첼은 머신러닝을 다음과 같이 정의함

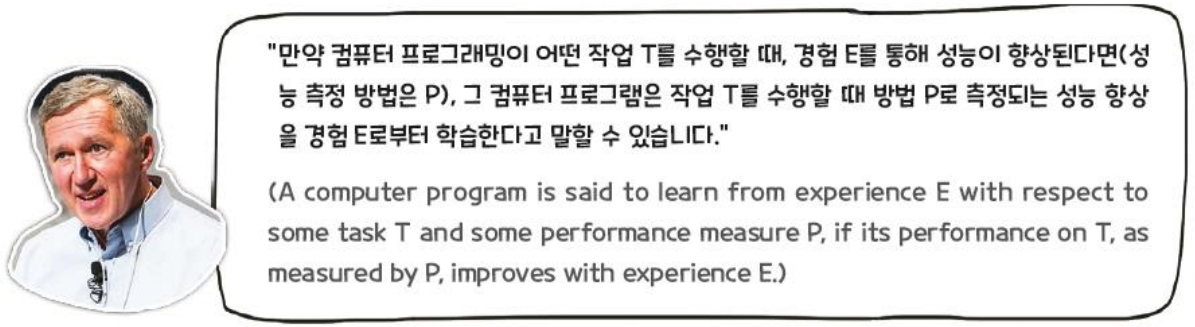

그림 2-3 톰 미첼의 머신러닝 정의

  - 만약 머신러닝 방식으로 고양이 판별 프로그램을 개발한다면, 고양이 판별 정확도를 높이기 위해 프로그램에 수많은 고양이 사진들을 입력해 훈련시켜야 함
  - 이를 톰 미첼의 정의로 해석하면 [표 2-1]과 같음

표 2-1 고양이 판별 프로그램 예를 활용한 톰 미첼의 머신러닝 정의 해석

작업 T, 성능 측정 P, 경험 E	해석
• T : 고양이 판별하기 • P : 고양이 판별 정확도 • E : 고양이 사진 입력	〈고양이 판별하기〉 작업을 수행할 때 '고양이 사진 입력'으로 '고양이 판별 정확도'가 향상된다면, 이 프로그램은 〈고양이 판별하기〉 작업을 수행할 때 '고양이 판별 정확도'의 성능을 향상시키기 위해 '고양이 사진 입력'이란 경험으로부터 학습합니다.

01. 머신러닝이란?

- **머신러닝은 언제 주로 사용될까? (1/2)**
  - 명시적으로 알고리즘을 설계하고 프로그래밍 하는 것이 어렵거나 불가능 한 경우에 주로 사용됨
    - ① 문제에서 나타날 수 있는 경우의 수가 너무 많은 경우
    - ② 규칙 기반 프로그램으로 답을 내기가 어려운 경우
  - 예를 들어
    - ① 바둑 경기에서 모든 경우의 수를 찾아서 if-else와 같은 문장으로 처리하는 것은 거의 불가능함
    - ② 스팸 메일을 자동으로 걸러내는 작업에도 많은 경우가 있기 때문에 프로그래밍하는 것은 거의 불가능함

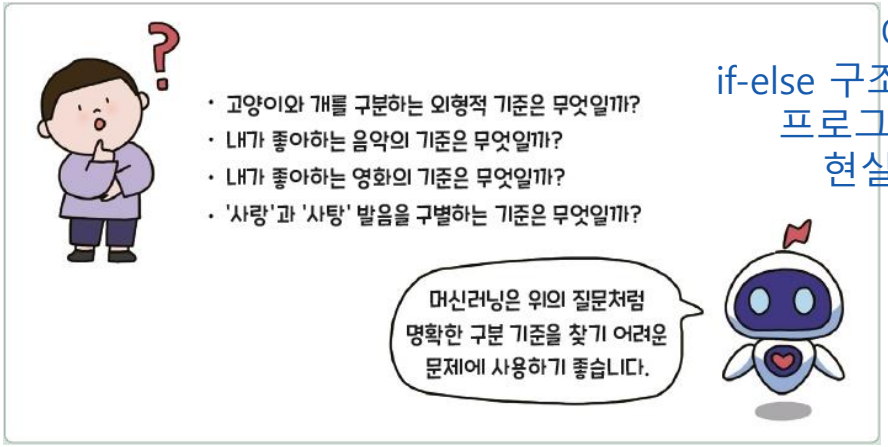

이러한 문제를
if-else 구조를 사용하여 처리하는
프로그램을 만든다는 것은
현실적으로 불가능함

01. 머신러닝이란?

- **머신러닝은 언제 주로 사용될까? (2/2)**
  - 머신러닝의 응용 분야
    - 주로, 복잡한 데이터들이 있고 이 데이터들에 기반하여 결정을 내려야 하는 분야
    - 머신러닝 모델을 학습 (Learning) 시키려면 많은 데이터가 필요하기 때문에 머신러닝은 빅데이터 (Big Data)와 아주 밀접한 관계가 있음
    - 예를 들어
      - 객체 검출 (Object Detection)
      - 음성 인식 (Voice Recognition)
      - 글자 인식 (Character Recognition)

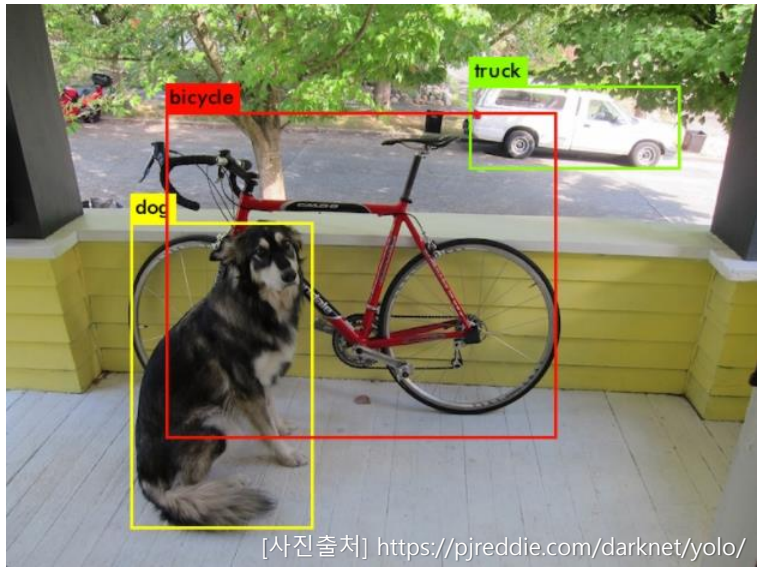

[사진출처] https://pjreddie.com/darknet/yolo/

01. 머신러닝이란?

- **머신러닝 구현 과정 예제 (1/4)**
  - 사람의 키를 입력했을 때 몸무게를 추측하는 작업을 머신러닝으로 구현하면?
  - ① 일반적으로 키가 커지면 몸무게도 늘어날 것이라 가정해,
    [몸무게 = a × 키 + b]와 같은 직선의 방정식을 만들어 머신러닝 모델로 가정

$$\text{몸무게} = a \times \text{키} + b$$
$$y = a \times x + b$$

그림 2-5 머신러닝 구현 과정 예제의 학습 데이터 © Hanbit Academy Inc.

		x	y
No.	이름	키 (cm)	몸무게 (kg)
1	김민성	100	30
2	박다인	120	40
3	윤이안	130	45
4	최서연	160	60
5	문진승	190	75

01. 머신러닝이란?

- **머신러닝 구현 과정 예제 (2/4)**
  - 사람의 키를 입력했을 때 몸무게를 추측하는 작업을 머신러닝으로 구현하면?

  ② 머신러닝 모델로 가정한 직선의 방정식은 아직 기울기 a와 y절편 b의 값이 결정되지 않은 상태로, 학습 데이터를 확보하여 최적화된 직선을 구함

  - 학습 데이터와 최적화된 직선을 구한다는 것은 학습 데이터와 오차가 가장 적은 직선의 기울기 (= a)와 y절편 (= b)을 구한다는 의미

		x	y
No.	이름	키 (cm)	몸무게 (kg)
1	김민성	100	30
2	박다인	120	40
3	윤이안	130	45
4	최서연	160	60
5	문진승	190	75

$$몸무게 = a \times 키 + b$$
$$y = a \times x + b$$

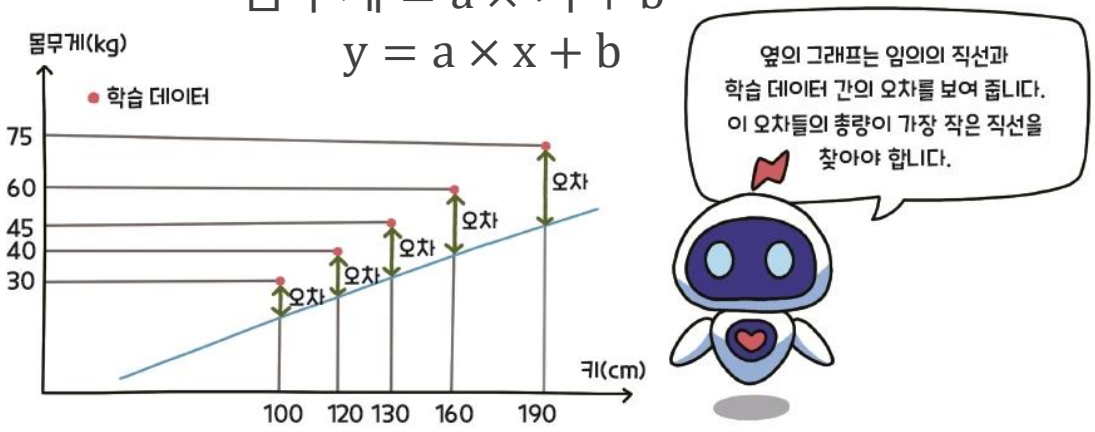

그림 2-6 학습 데이터와 직선 간의 오차

01. 머신러닝이란?

- **머신러닝 구현 과정 예제 (3/4)**
  - 사람의 키를 입력했을 때 몸무게를 추측하는 작업을 머신러닝으로 구현하면?

② 머신러닝 모델로 가정한 직선의 방정식은 아직 기울기 a와 y절편 b의 값이 결정되지 않은 상태로, 학습 데이터를 확보하여 최적화된 직선을 구함

- 학습 결과, 직선의 방정식 [몸무게 = (0.5 × 키) – 20]이 해당 학습 데이터에 최적화된 함수임

		x	y
No.	이름	키 (cm)	몸무게 (kg)
1	김민성	100	30
2	박다인	120	40
3	윤이안	130	45
4	최서연	160	60
5	문진승	190	75

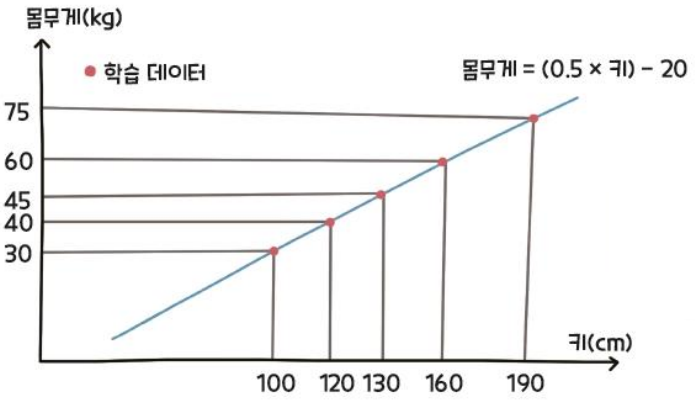

그림 2-7 몸무게와 키의 상관관계에 최적화된 직선의 방정식 © Hanbit Academy Inc.

$$\text{몸무게} = a \times \text{키} + b$$

$$y = a \times x + b$$

↓

최적화 (Optimization)

$$a = 0.5$$

$$b = -20$$

↓

$$y = 0.5 \times x - 20$$

01. 머신러닝이란?

- **머신러닝 구현 과정 예제 (4/4)**
  - 사람의 키를 입력했을 때 몸무게를 추측하는 작업을 머신러닝으로 구현하면?
  - ③ 최적화된 머신러닝 모델을 실제 문제에 적용해 확인
    - 학습 데이터에는 없던 키 180cm를 방정식에 대입하면 예측되는 몸무게는 [70kg = (0.5×180) – 20]이 나옴

Q) 키가 180cm 인 사람은 몸무게가 몇 kg일까?

		x	y
No.	이름	키 (cm)	몸무게 (kg)
1	김민성	100	30
2	박다인	120	40
3	윤이안	130	45
4	최서연	160	60
5	문진승	190	75

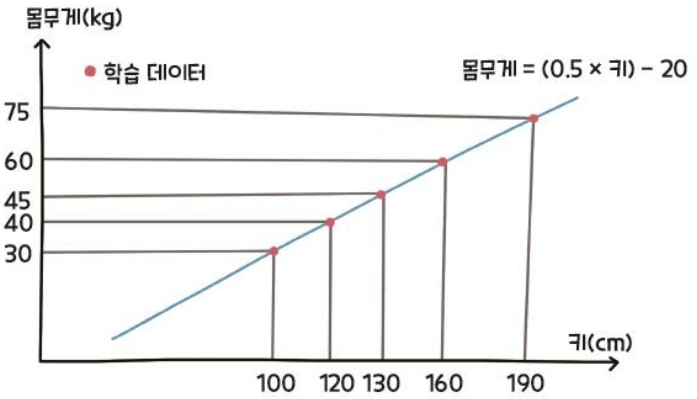

그림 2-7 몸무게와 키의 상관관계에 최적화된 직선의 방정식 © Hanbit Academy Inc.

$$y = 0.5 \times x - 20$$

↓

$$x = 180 \text{ 대입}$$

↓

$$y = 0.5 \times 180 - 20$$
$$= 90 - 20$$
$$= 70$$

AI Experts
Who Lead
The Future

02

머신러닝 학습방법

다음 자료를 기반으로 제작
난생처음 인공지능 입문 (출판사: 한빛아카데미)

머신러닝의 종류

- **머신러닝 모델을 학습시킴에 있어**
  - 입력값에 대한 결과값을 알고 있는지 여부에 따라
    - **"지도학습"과 "비지도 학습"으로 나누어짐**

문제 ↔ 입력값
정답 ↔ 결과값, 레이블 (Label)

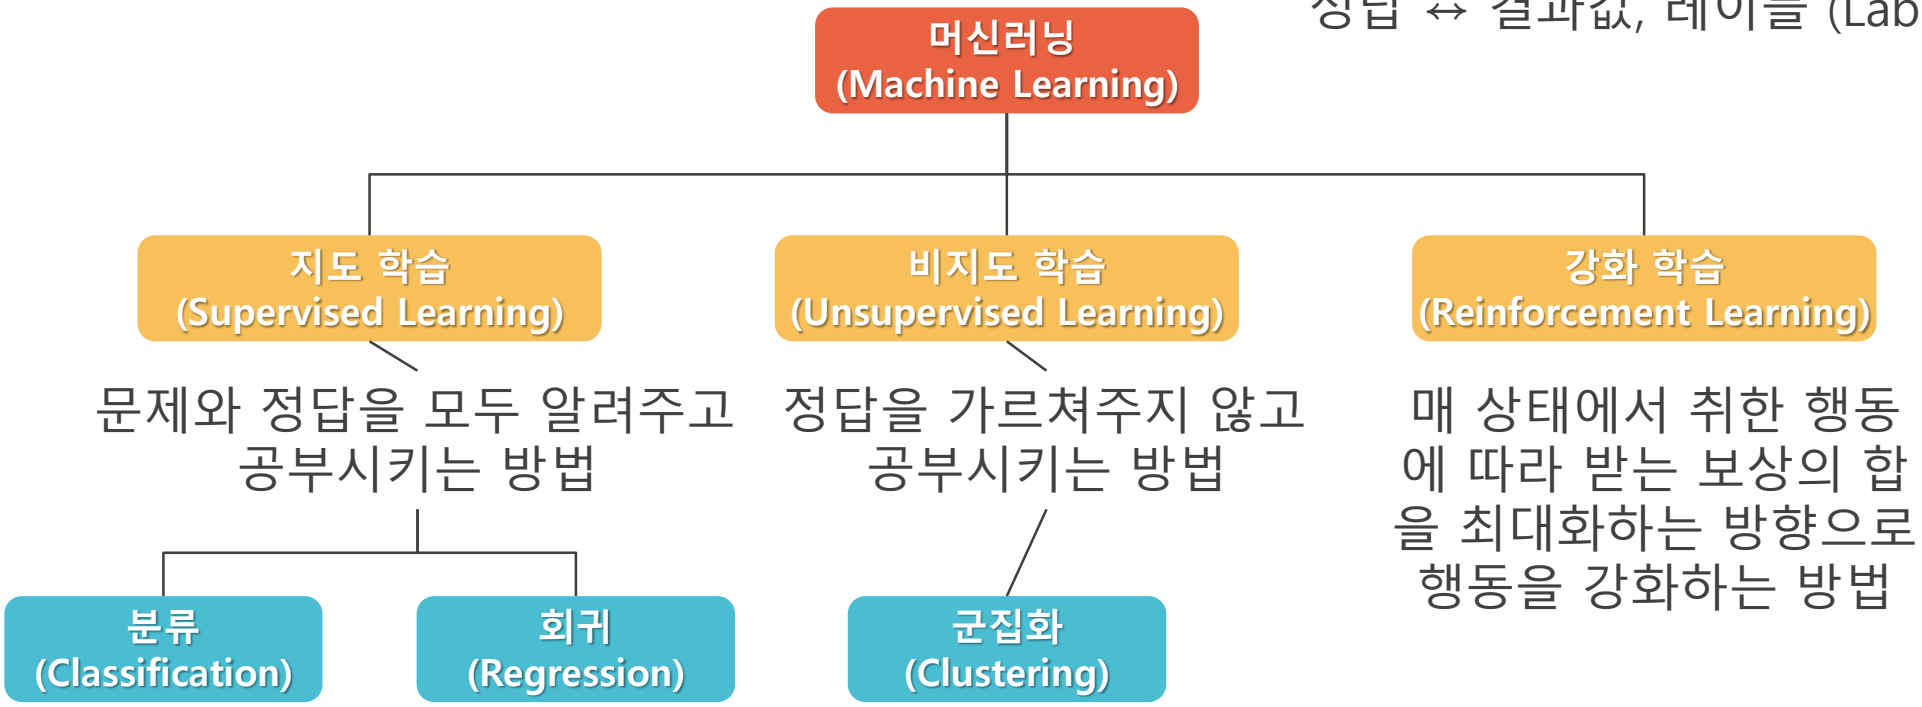

① 지도학습 (Supervised Learning)

- 입력값에 대한 정답 (=결과값)을 알고 있는 학습 데이터를 활용하여 머신러닝 모델을 학습시키는 방식
- 입력값에 대한 정답 (=결과값)을 레이블 (Label)이라고 함

그림 2-8 구분된 학습 데이터를 활용하는 지도학습의 예 © Hanbit Academy Inc.

지도학습 유형

- 분류 (Classification)와 회귀 (Regression)라는 2가지 유형
  - ⓐ 분류 (Classification)
    - 어떤 입력 데이터가 들어오더라도 학습에 사용한 레이블 (Label)중 하나로 결과값을 결정
    - 레이블 (Label)이 이산적인 (Discrete) 경우 (즉, [0, 1, 2, 3, …]와 같이 유한한 경우)
      - Ex) 이미지가 주어졌을 때, 고양이 (Class = 0) 이미지인지 또는 개 (Class = 1) 이미지인지 분류
  - ⓑ 회귀 (Regression)
    - 입력 데이터에 대한 결과값으로 학습에 사용한 레이블 이외의 값이 나올 수 있음
    - 레이블 (Label)이 실수인 경우
      - Ex) 키 (Height) 정보가 주어졌을 때, 몸무게를 예측

표 2-2 지도학습을 적용한 머신러닝 모델의 작업

작업	내용
분류	입력값에 대한 결과값이 정해진 레이블 중 하나로 결정되는 작업을 의미
회귀	입력값에 대한 결과값이 학습에 사용된 레이블 외의 값도 나올 수 있는 작업을 의미

ⓐ 분류 (Classification) 작업

- **대표적인 예: 필기체 (손글씨) 인식**
  - 0부터 9까지의 손글씨 숫자 이미지와 레이블 (Label) 정보를 학습 데이터로 사용
  - 어떤 이미지라도 (심지어는 숫자 이미지가 아니더라도) 0부터 9까지의 레이블 중 하나로 결과값을 결정함

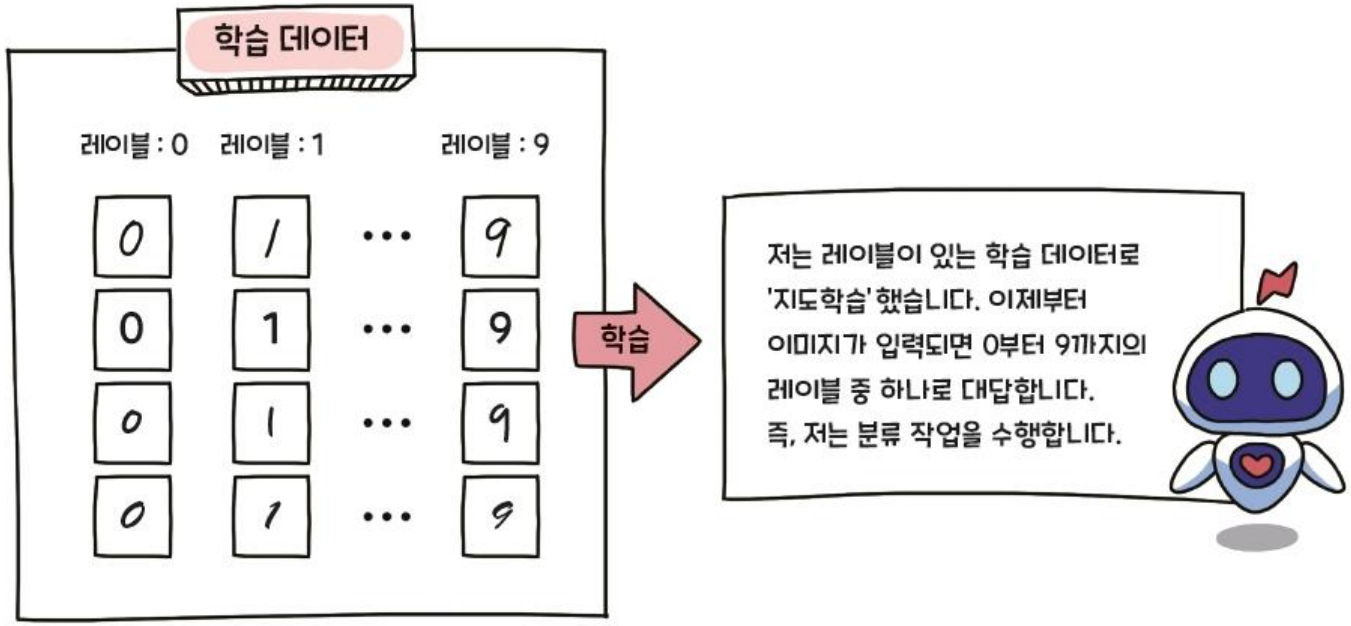

그림 2-9 머신러닝의 분류 작업 예 : 숫자 필기체 인식하기

ⓑ 회귀 (Regression) 작업

- **대표적인 예: 몸무게 예측 작업**
  - 여러 명의 키와 그에 대응하는 몸무게를 학습 데이터로 사용하는데, 입력된 키에 대한 몸무게를 결과값으로 출력하기 때문에 몸무게가 레이블 (Label)이 됨
  - 다양한 키에 대해서 레이블에 포함되지 않은 몸무게도 결과값으로 출력 가능

No.	이름	키 (cm)	몸무게 (kg)
1	김민성	100	30
2	박다인	120	40
3	윤이안	130	45
4	최서연	160	60
5	문진승	190	75

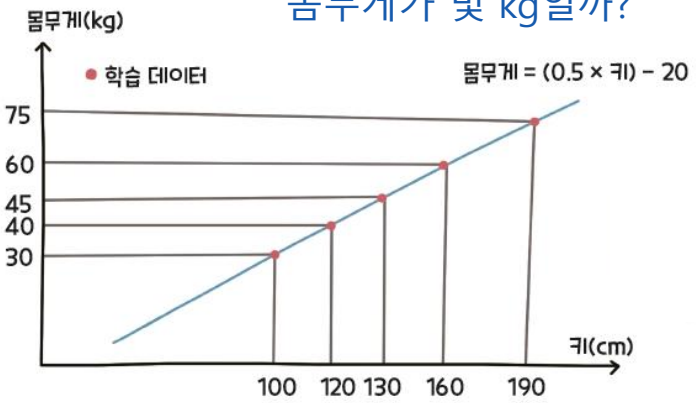

그림 2-7 몸무게와 키의 상관관계에 최적화된 직선의 방정식 © Hanbit Academy Inc.

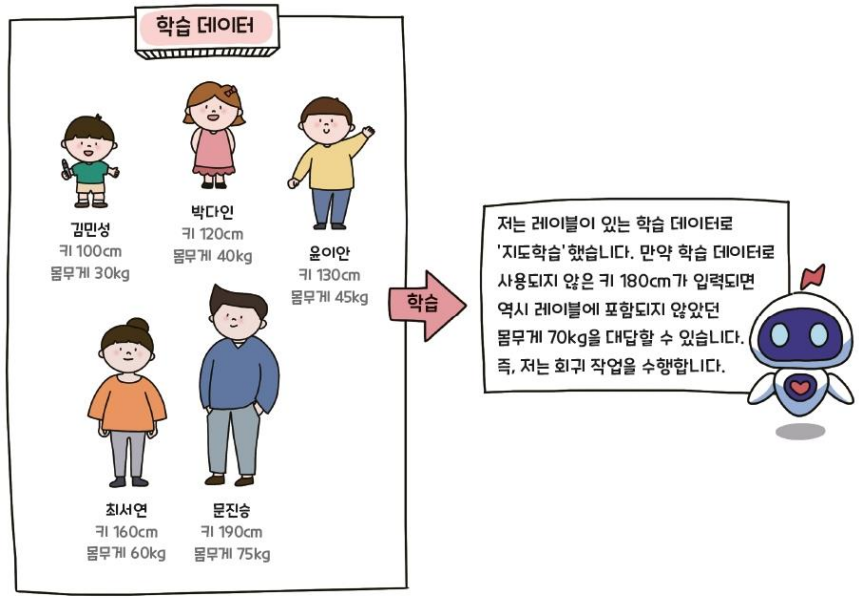

그림 2-10 머신러닝의 회귀 작업 예 : 키로 몸무게 예측하기 © Hanbit Academy Inc.

② 비지도학습 (Unsupervised Learning)

- **정의**
  - 입력값에 대한 정답 (=결과값)이 없는, 즉 레이블 (Label)이 없는 데이터를 사용하여 머신러닝 모델을 학습시키는 방식
  - 비지도학습에는 대표적으로 군집화 (Clustering)라는 방법이 있음
- **군집화 (Clustering)**
  - 레이블 (Label) 없이
    - 데이터 간에 존재하는 특성을 바탕으로 비슷한 데이터 구분하여 비슷한 집단으로 묶는 작업
  - 군집 작업은 마케팅 분야에서 많이 응용
    - 예를 들어, 채팅 사이트를 운영하는 기업이 사람들의 대화 내용을 기반으로 군집 작업을 수행해 취미를 속성으로 묶었다면, 집단별로 인구통계학적 특성을 파악해 적절한 취미용품을 광고할 수 있음

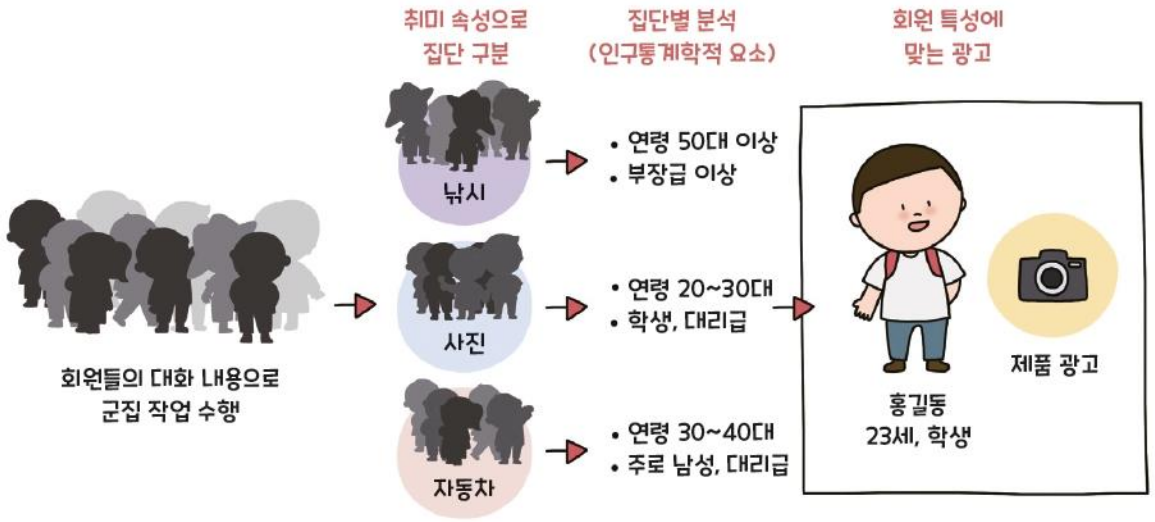

그림 2-12 마케팅 분야의 군집 작업 활용 예

③ 강화학습 (Reinforcement Learning) (1/2)

- 입력값에 대한 정답 (=결과값) 대신 어떤 일을 잘했을 때 보상 (Reward)을 주는 것으로 머신러닝 모델을 학습시키는 방식
  - 핵심 목표
    - 시행착오를 통해 보상의 총합이 최대가 되는 일련의 행동을 찾는 것
    - 나중에 더 큰 이익을 기대하며 지금의 손해를 감수하는 식의 전략적 행동을 탐색할 수 있다는 의미와 같음
  - 응용분야
    - 게임 전략, 금융시장의 투자 전략, 광고 노출 전략 등과 같은 사업 분석 분야
    - 로봇 팔 제어, 이족보행 제어와 같은 로보틱스 분야에서 널리 응용되고 있으며,
    - 자율주행 분야에서도 핵심 기술로 활용되고 있음

③ 강화학습 (Reinforcement Learning) 사례

(a) 슈퍼마리오(https://www.youtube.com/watch?v=WzxmH1Cx2Yg)

(b) 쿠키런(https://www.youtube.com/watch?v=exXD6wJLJ6s)

그림 2-13 강화학습을 통한 게임 제어 활용 예 © Hanbit Academy Inc.

(a) 로봇 팔 제어 : 탁구(https://www.youtube.com/watch?v=SH3bADiB7uQ)

(b) 로봇 팔 제어 : 팬케이크 뒤집기(https://www.youtube.com/watch?v=W_gxLKSsSIE)

AI Experts
Who Lead
The Future

03

지도학습의 분류 알고리즘

다음 자료를 기반으로 제작
난생처음 인공지능 입문 (출판사: 한빛아카데미)

분류 (Classification) 개요

- **레이블이 포함된 데이터를 학습하고 유사한 성질을 갖는 데이터끼리 분류한 후, 새로 입력된 데이터가 어느 그룹에 속하는지를 찾아내는 기법**
  - 어떤 입력 데이터가 들어오더라도 학습에 사용한 레이블 (Label)중 하나로 결과값을 결정
  - 레이블 (Label)이 이산적인 (Discrete) 경우 (즉, [0, 1, 2, 3, …]와 같이 유한한 경우)

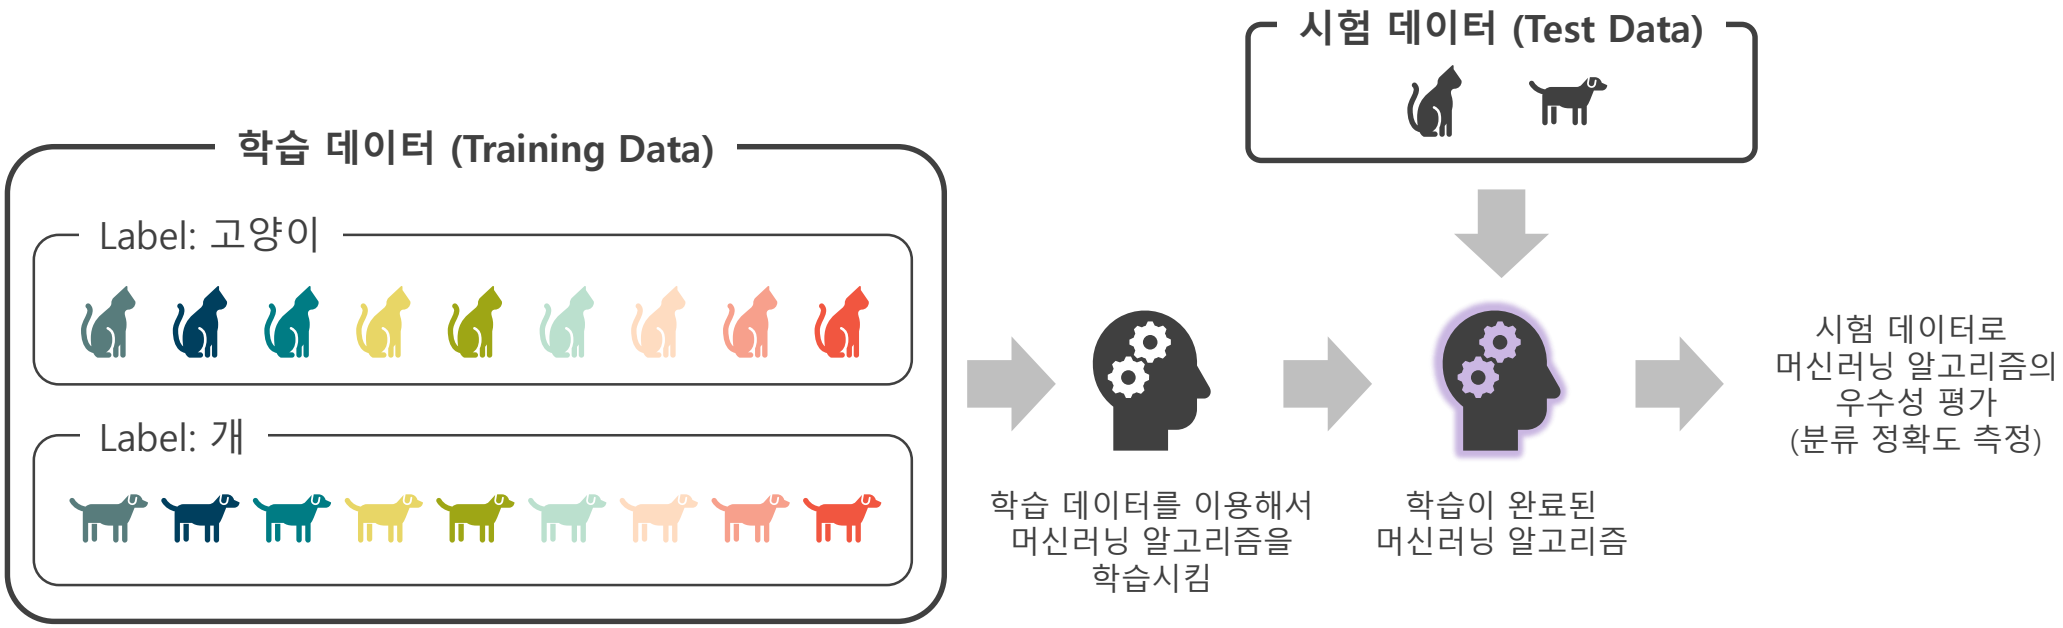

분류 (Classification)의 종류

이진 분류 (Binary Classification)

- 데이터를 2개의 그룹 (Class)으로 분류

Label: 고양이

Label: 개

"고양이" or "개"

둘 중에 하나로 분류

다중 분류 (Multiclass Classification)

- 데이터를 3개의 그룹 (Class) 이상으로 분류

Label: 고양이

Label: 개

Label: 토끼

"고양이" or "개" or "토끼"

셋 중에 하나로 분류

지도학습 알고리즘의 학습 및 시험 단계 (Training & Test Phases)

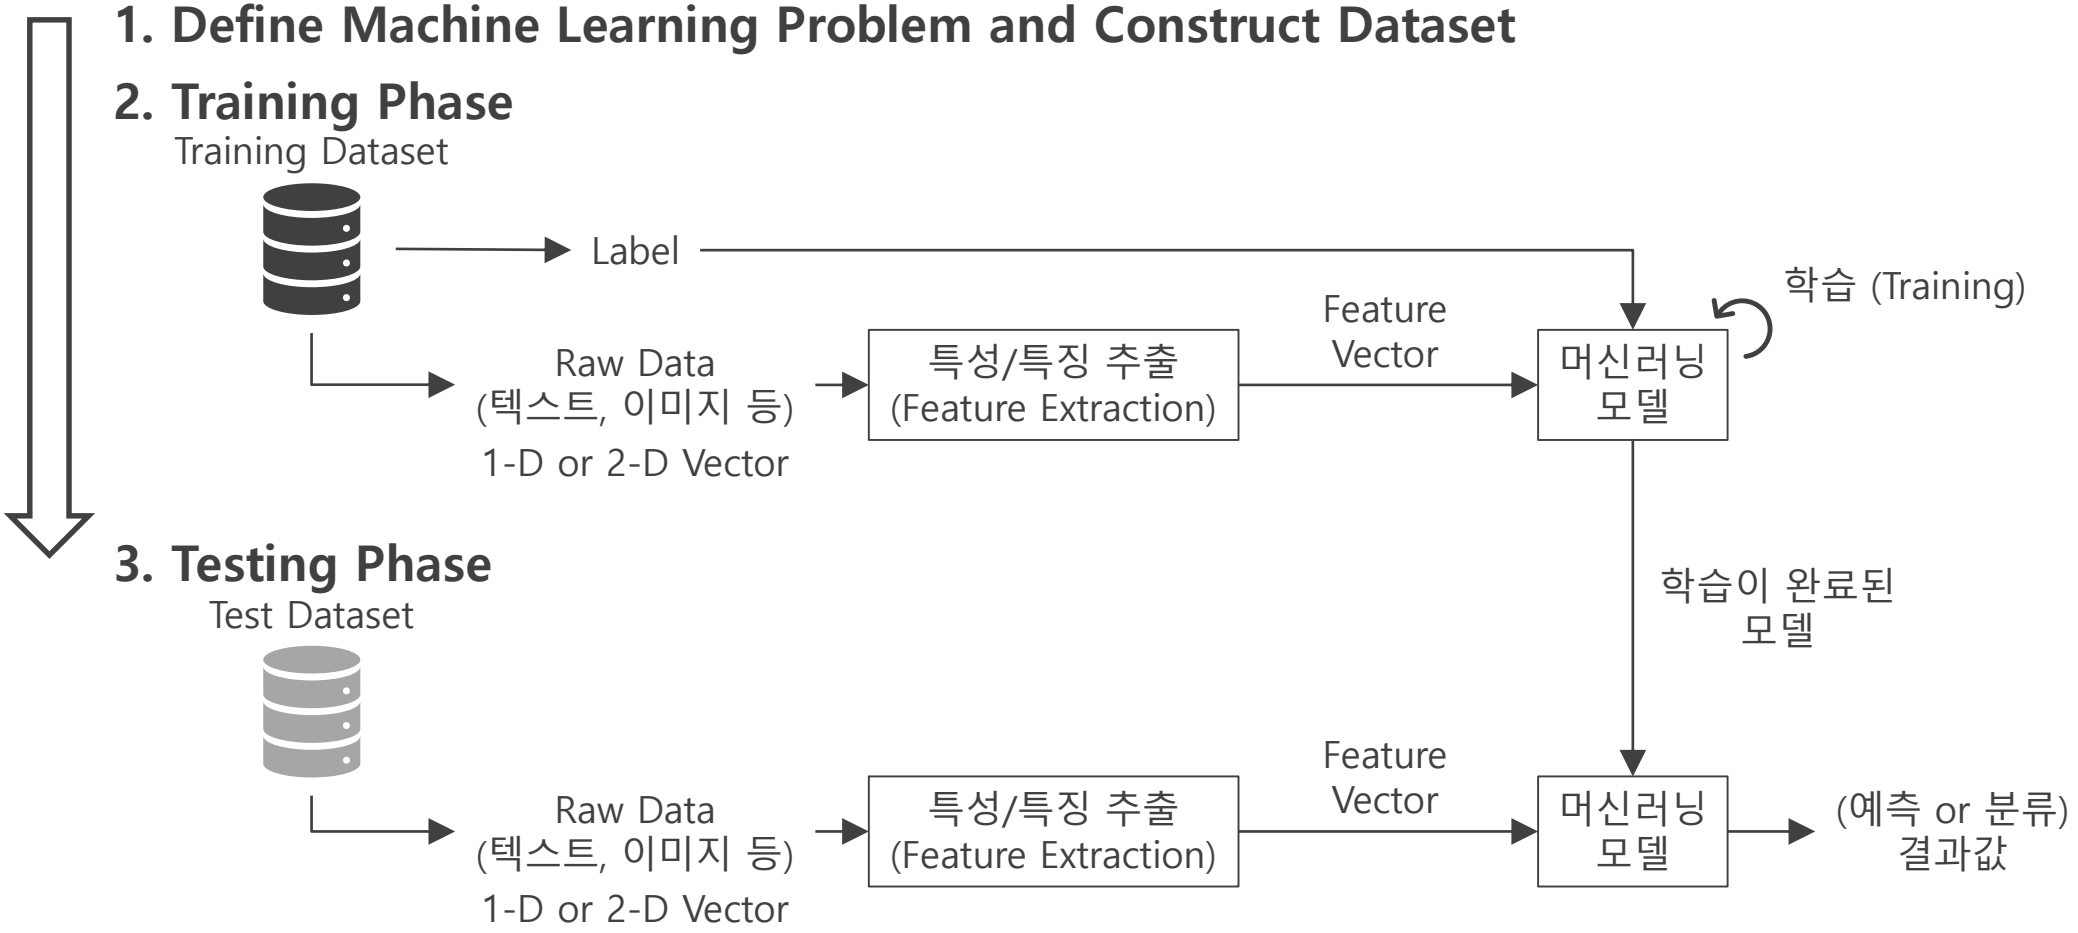

특성/특징 추출 (Feature Extraction) (1/4)

상상해 봅시다!

아래 이미지들을 보고 연상되는 동물은?

꼬리

귀

발바닥

코

무늬

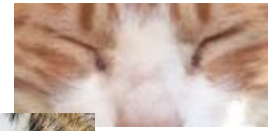

눈

수염

특성/특징 추출 (Feature Extraction) (2/4)

- **사람은 어떻게 고양이 신체의 일부분 이미지들만 보고도, "고양이"라는 것을 어떻게 추론해 낼까요?**

사람은 지금까지 살아오면서
다양한 고양이를 봐왔고,
"고양이"라면 갖고 있는 특징들을
이미 학습을 통해 알고 있다.

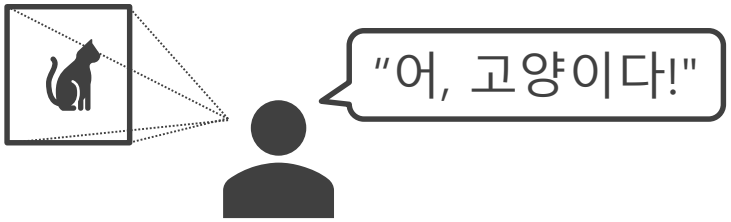

특징 #1: 뾰족한 귀

특징 #2: 긴 꼬리

특징 #3: 핑크색 발바닥

특징 #4: 무늬 (삼색, 치즈색, 고등어색)

. . .

<고양이라면 갖고 있는 몇가지 특징들>

특성/특징 추출 (Feature Extraction) (3/4)

- **그렇다면, 머신러닝 모델이 주어진 이미지를 보고 고양이로 인지 할 수 있게 하려면 어떻게 해야 할까?**
  - **Feature Extraction**
    - **머신러닝 모델이 잘 학습할 수 있도록 학습 데이터 (Training Data)로부터 특성/특징 정보를 뽑아내는 작업**

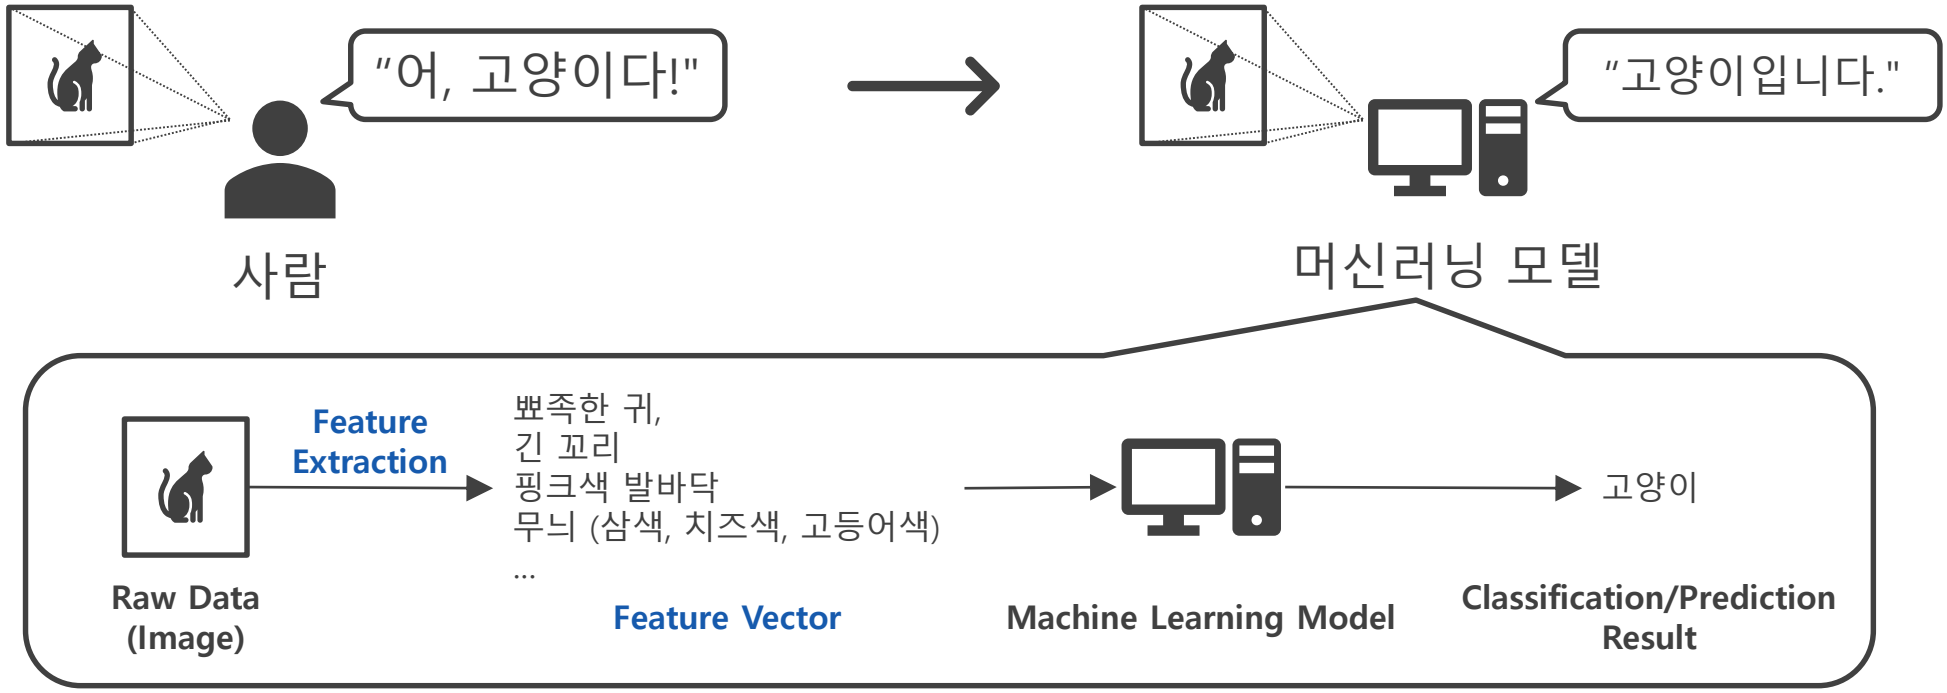

특성/특징 추출 (Feature Extraction) (4/4)

- **Good and Bad Features**

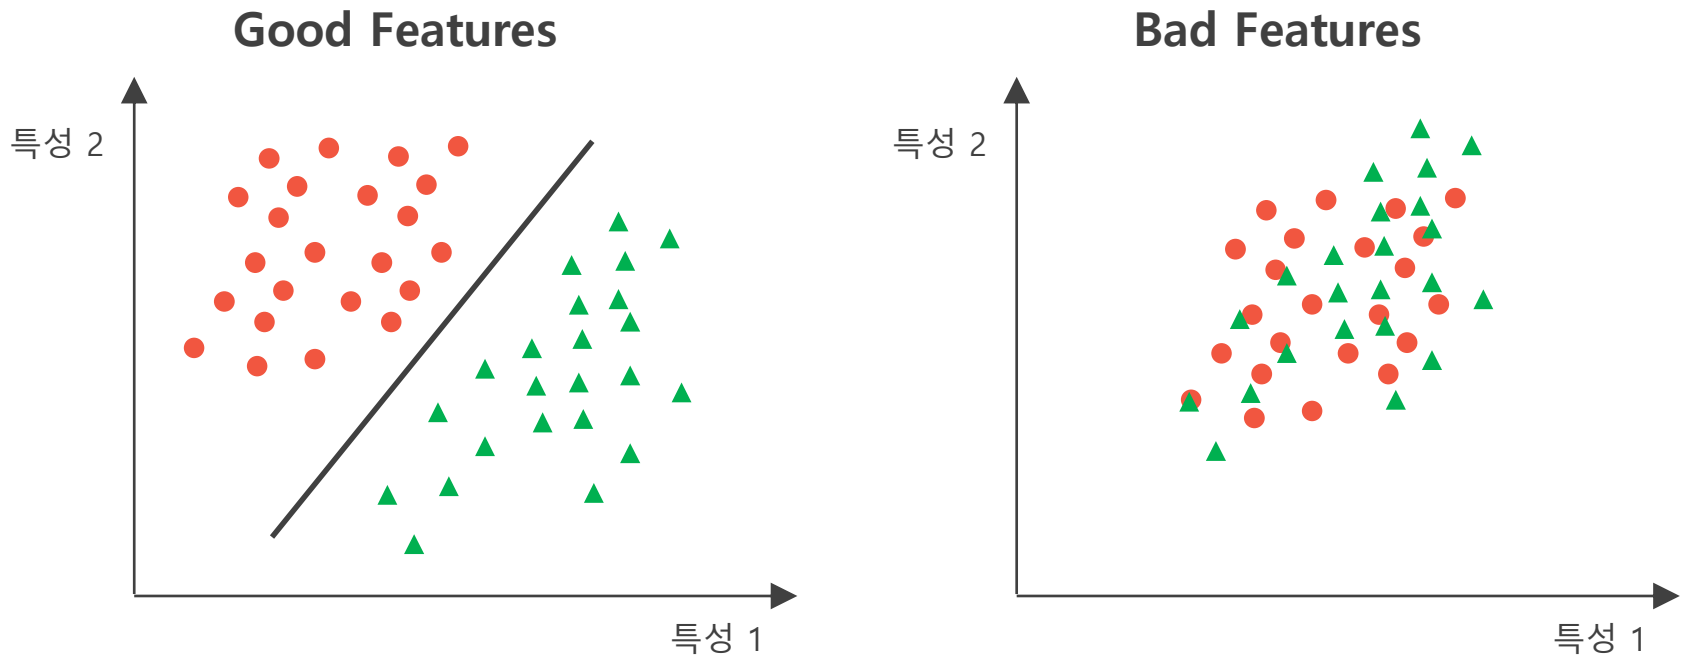

좋은 Features를 설계 (Design) 하는 것이 매우 중요하다!

분류 (Classification) 문제를 해결하기 위한 기법

- ① k-최근접 이웃 (k-Nearest Neighbors, k-NN)
- ② 결정 트리 (Decision Tree)
- ③ 랜덤 포레스트 (Random Forest)
- ④ 서포트 벡터 머신 (Support Vector Machine, SVM)
- ⑤ 앙상블 학습 (Ensemble Learning)

① k-최근접 이웃 (k-Nearest Neighbors, k-NN) (1/10)

인공지능 활용 Python language

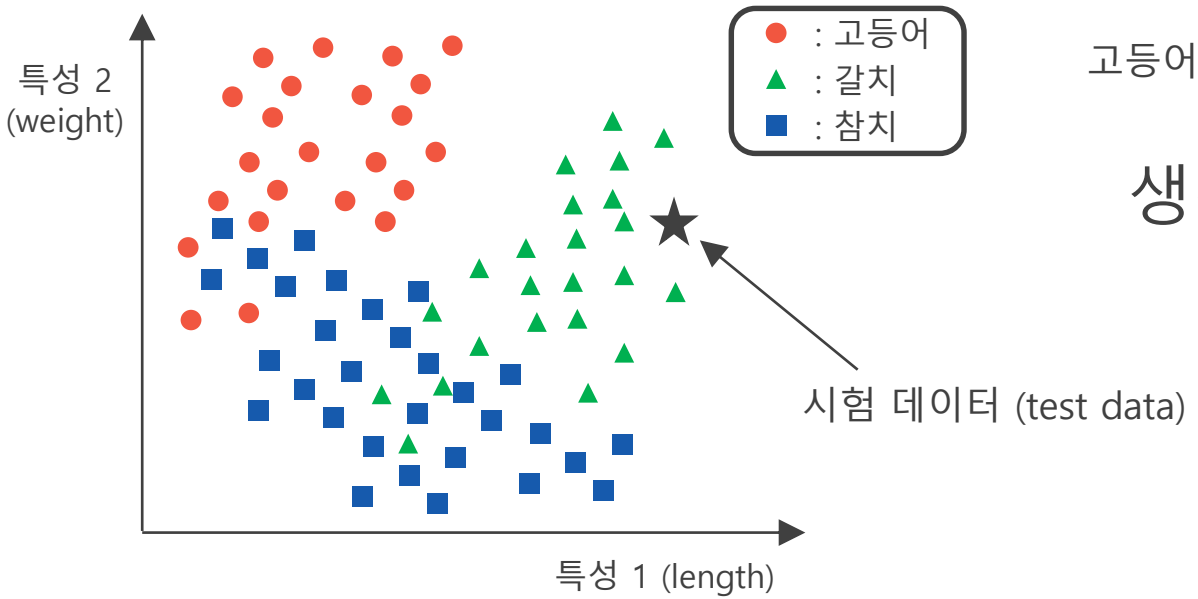

수산시장에서 일하고 있는 동양이는
고등어, 갈치, 참치를 분류하는 장비를 개발하려고 한다.

생선 ★의 Label은 무엇일까?

★ 주변에 갈치 ▲가 많은데...

① k-최근접 이웃 (k-Nearest Neighbors, k-NN) (2/10) 인공지능 활용 Python language

- ① k-최근접 이웃 (k-Nearest Neighbors, k-NN) (2/10)
  - 시험 데이터가 주어졌을 때, 시험 데이터로부터 거리가 가장 가까운 k개의 학습 데이터의 Labels을 참조하여 시험 데이터가 어떤 Label에 속하는지 분류하는 알고리즘
  - 예를 들어,
    - $k = 1$일 때, 시험 데이터는 ● 빨간색 원으로 분류됨
    - $k = 3$일 때, 시험 데이터는 ▲ 초록색 삼각형으로 분류됨
    - $k = 6$일 때, 시험 데이터는 ■ 파란색 사각형으로 분류됨

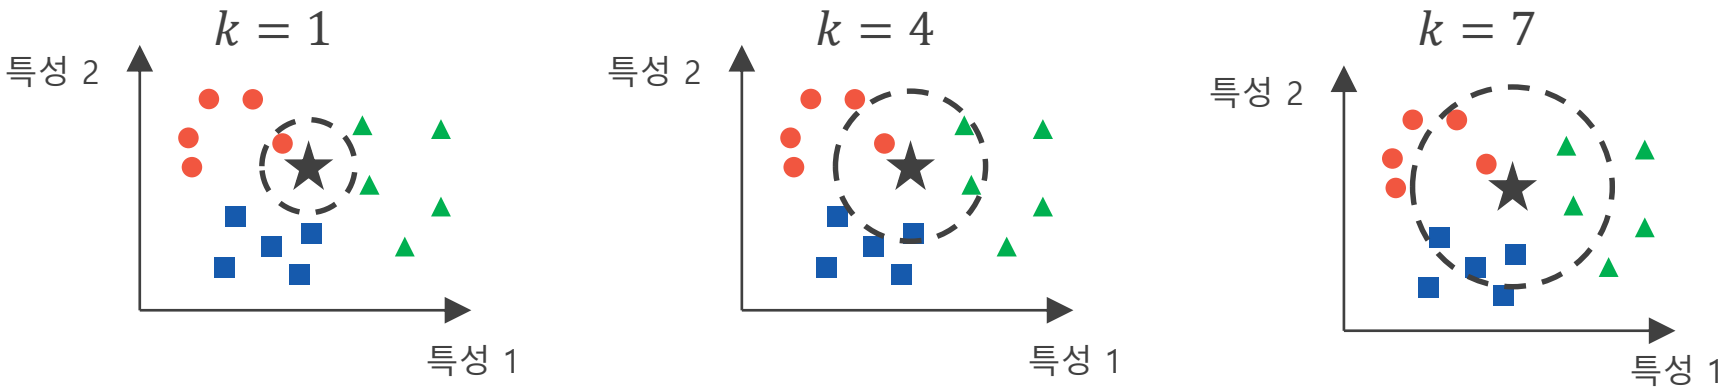

① k-최근접 이웃 (k-Nearest Neighbors, k-NN) (3/10) 인공지능 활용 Python language

- ① k-최근접 이웃 (k-Nearest Neighbors, k-NN) (3/10)
  - 어떤 값이 최적의 k인지 불분명하기 때문에 데이터의 특성에 맞게 k 값을 임의로 선정해야 하는 단점이 있음
  - 일반적으로 이진 분류 (Binary Classification)문제에서는 k 값을 홀수로 선정함

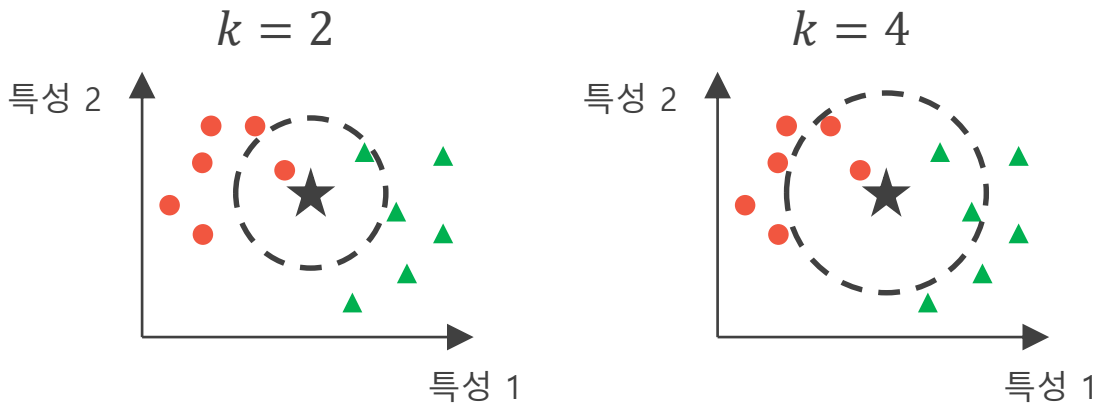

이진 분류 문제에서 k 값이 짝수인 경우, ★을 분류할 수 없다

① k-최근접 이웃 (k-Nearest Neighbors, k-NN) (4/10)

- **데이터 사이의 거리를 계산하기 위해서, 유클리드 거리 (Euclidean Distance)가 주로 사용됨**

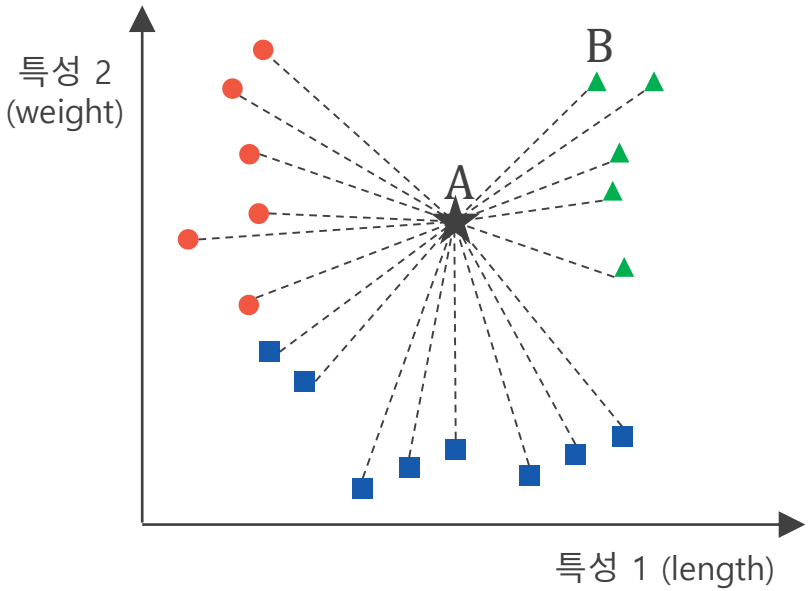

➢ Dimension of Feature Vector = 2

$A(p_1, p_2)$

$B(q_1, q_2)$

$$d = \overline{AB} = \sqrt{(p_1 - q_1)^2 + (p_2 - q_2)^2}$$

➢ Dimension of Feature Vector = 3

$A(p_1, p_2, p_3)$

$B(q_1, q_2, q_3)$

$$d = \overline{AB} = \sqrt{(p_1 - q_1)^2 + (p_2 - q_2)^2 + (p_3 - q_3)^2}$$

➢ Dimension of Feature Vector = n

$$d = \overline{AB} = \sqrt{(p_1 - q_1)^2 + (p_2 - q_2)^2 + \cdots + (p_i - q_i)^2 + \cdots + (p_n - q_n)^2}$$

- ① k-최근접 이웃 (k-Nearest Neighbors, k-NN) (5/10)

학습 데이터셋 (Training Dataset)

	Class	특성 1 (length)	특성 2 (weight)
갈치	0	25.4	3.7
	0	23.5	3.3
	0	24.7	3.5
	…	…	…
고등어	1	10.9	2.4
	1	9.7	2.1
	1	10.2	2.3
	…	…	…

시험 데이터
(Test Data)

(특성 1, 특성 2) = (24.3, 3.4)

Class 0 (갈치)에 속할까?

아니면

Class 1 (고등어)에 속할까?

① k-최근접 이웃 (k-Nearest Neighbors, k-NN) (1/10)

인공지능 활용 Python language

학습 데이터셋 (Training Dataset)

	Class	특성 1 (length)	특성 2 (weight)	거리 (d)
갈치	0	25.4	3.7	**1.14**
	0	23.5	3.3	**0.81**
	0	24.7	3.5	**0.41**
	…	…	…	…
고등어	1	10.9	2.4	**13.44**
	1	9.7	2.1	**14.66**
	1	10.2	2.3	**14.14**
	…	…	…	…

시험 데이터
(Test Data)

(특성 1, 특성 2) = (24.3, 3.4)

Step 1) 학습 데이터셋에 있는 각 데이터들과 거리를 계

$$d = \sqrt{(p_1 - q_1)^2 + (p_2 - q_2)^2}$$

$$d = \sqrt{(24.3 - 25.4)^2 + (3.4 - 3.7)^2}$$
$$= 1.14$$

① k-최근접 이웃 (k-Nearest Neighbors, k-NN) (7/10)

인공지능 활용 Python language

학습 데이터셋 (Training Dataset)

	Class	특성 1 (length)	특성 2 (weight)	거리 (d)
갈치	0	25.4	3.7	**1.14**
	0	23.5	3.3	**0.81**
	0	24.7	3.5	**0.41**
	…	…	…	…
고등어	1	10.9	2.4	**13.44**
	1	9.7	2.1	**14.66**
	1	10.2	2.3	**14.14**
	…	…	…	…

Step 2) $k = 3$ **이라고 하면, 가장 작은 d 값 3개의 Class**

Class	거리 (d)
0	**1.14**
0	**0.81**
0	**0.41**

선별된 3개의 Class 중에서
다수를 차지하고 있는 Class를
시험 데이터의 Class로 결정

시험 데이터 (Test Data) → Class 0 (갈치)로 분류!

(특성 1, 특성 2) = (24.3, 3.4)

① k-최근접 이웃 (k-Nearest Neighbors, k-NN) (8/10) 인공지능 활용 Python language

- (주의 사항) 특성들 사이에 스케일 (Scale)을 맞춰야 한다

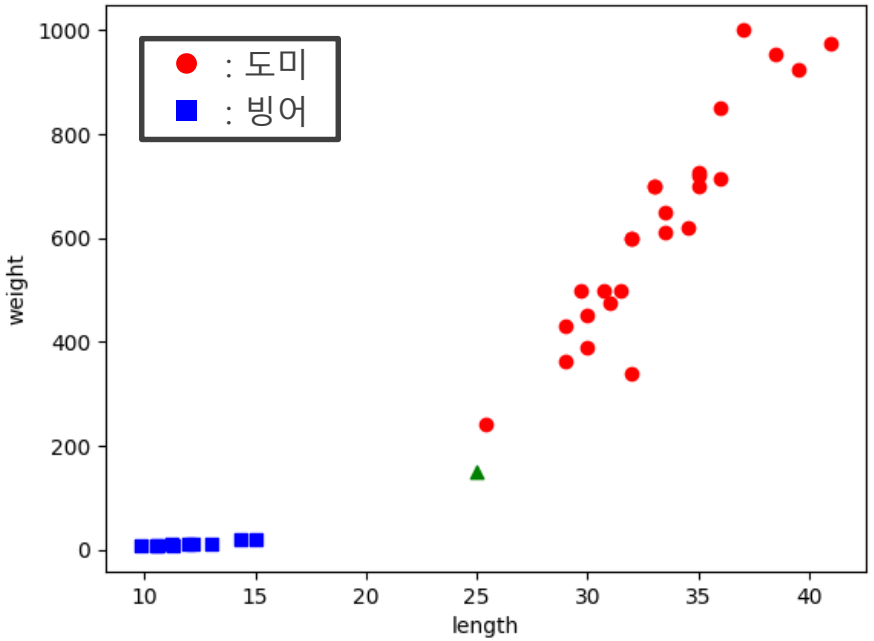

$k = 5$라고 가정해 보자!

생선 ▲의 Label은 무엇일까?

●랑 더 가까운 것 같은데...

① k-최근접 이웃 (k-Nearest Neighbors, k-NN) (9/10)

- (주의 사항) 특성들 사이에 스케일 (Scale)을 맞춰야 한다

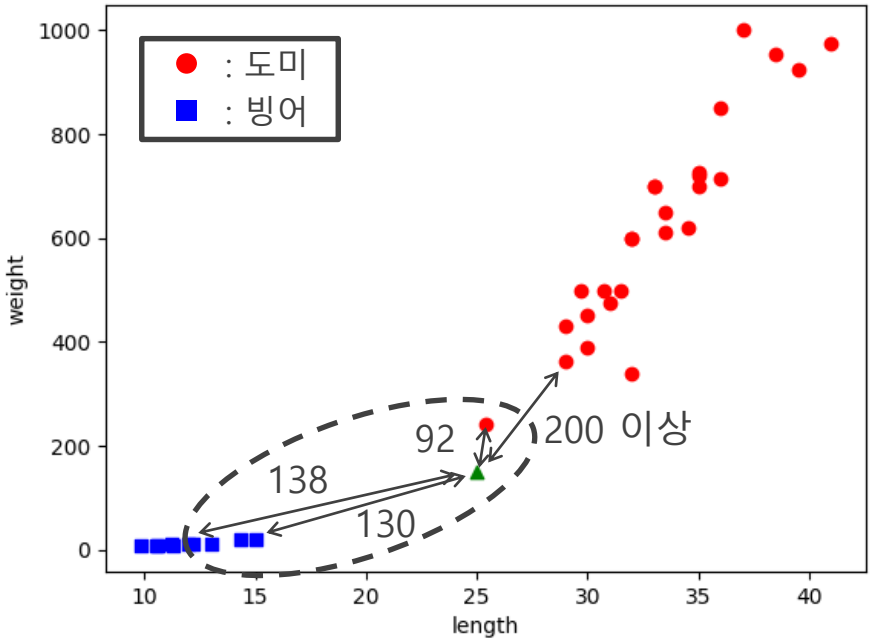

$k = 5$라고 가정해 보자!

▲랑 가까운 5개의 데이터를 표시해 보면?!

■ (빙어) 4개, ● (도미) 1개로 ▲는 빙어로 분류된다?!

왜 그럴까?!

① k-최근접 이웃 (k-Nearest Neighbors, k-NN) (10/10)

- **(주의 사항) 특성들 사이에 스케일 (Scale)을 맞춰야 한다**

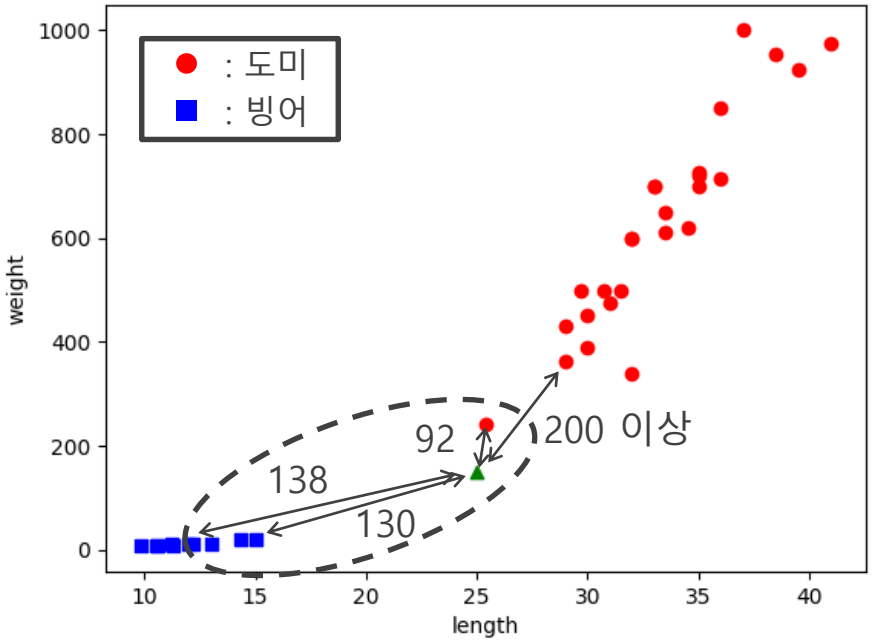

특성 1 (length)와 특성 2 (weight)의 Scale이 다르다!

쉽게 말해서, 두 특성이 갖는 값의 범위가 다르다!

$0 < \text{length} < 50$
$0 < \text{weight} < 1000$

Scale이 서로 다른 상태에서 유클리드 거리를 계산하면 k-NN 알고리즘이 올바르게 분류 작업을 할 수 없다!

Scale을 맞춰주는 작업: $x_{new} = \dfrac{x - x_{min}}{x_{max} - x_{min}}$

② 결정 트리 (Decision Tree) (1/8)

- 의사결정 규칙을 나무 형태로 분류하는 분석 방법
- [그림 8-19]와 같이 상위 노드에서 시작하여 분류 기준값에 따라 하위 노드로 확장하는 방식이
  "나무"를 닮았다고 하여 "의사 결정 나무"라고도 불림

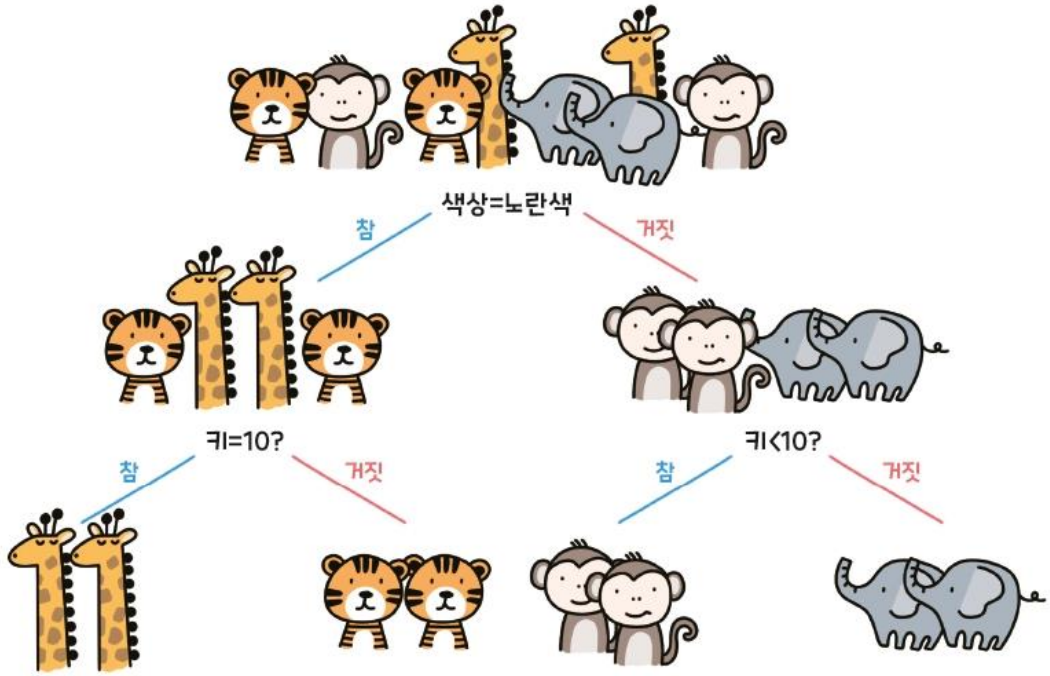

그림 8-19 의사결정나무 구조

② 결정 트리 (Decision Tree) (2/8)

- **Root Node**
- **Intermediate Node**
- **Terminal Node (Leaf Node)**

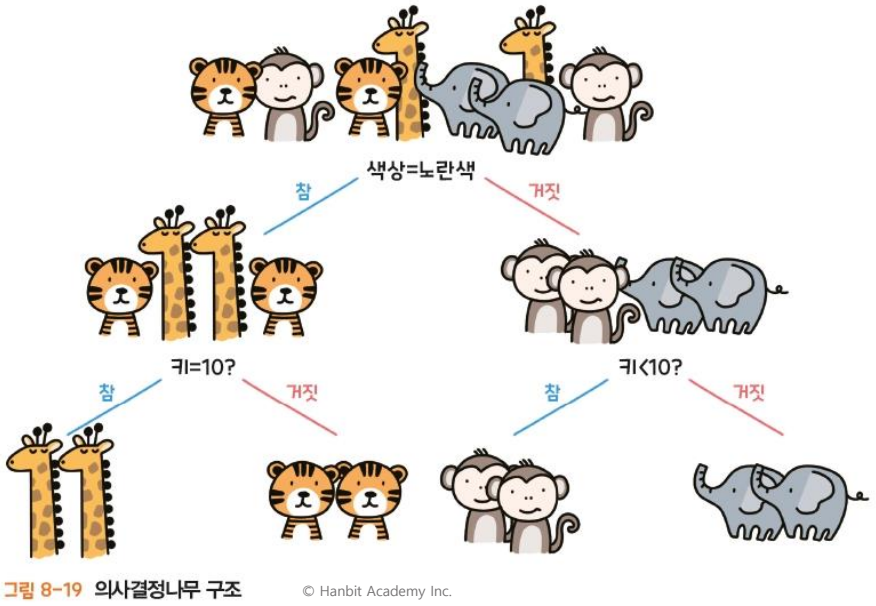

그림 8-19 의사결정나무 구조

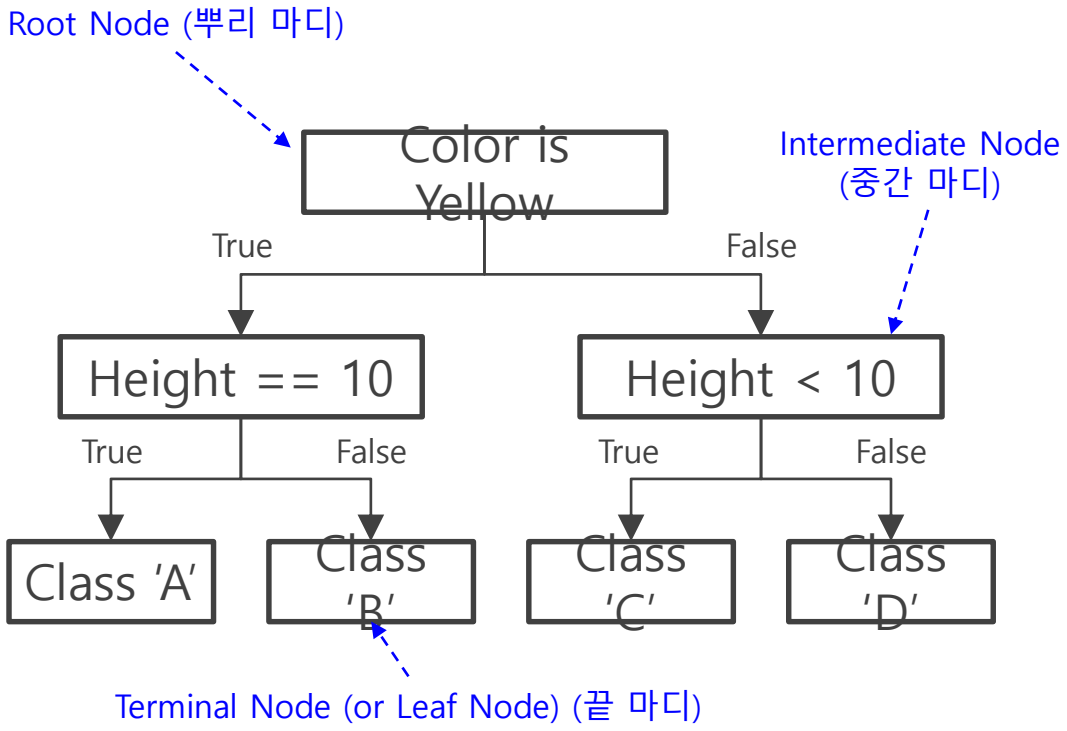

② 결정 트리 (Decision Tree) (3/8)

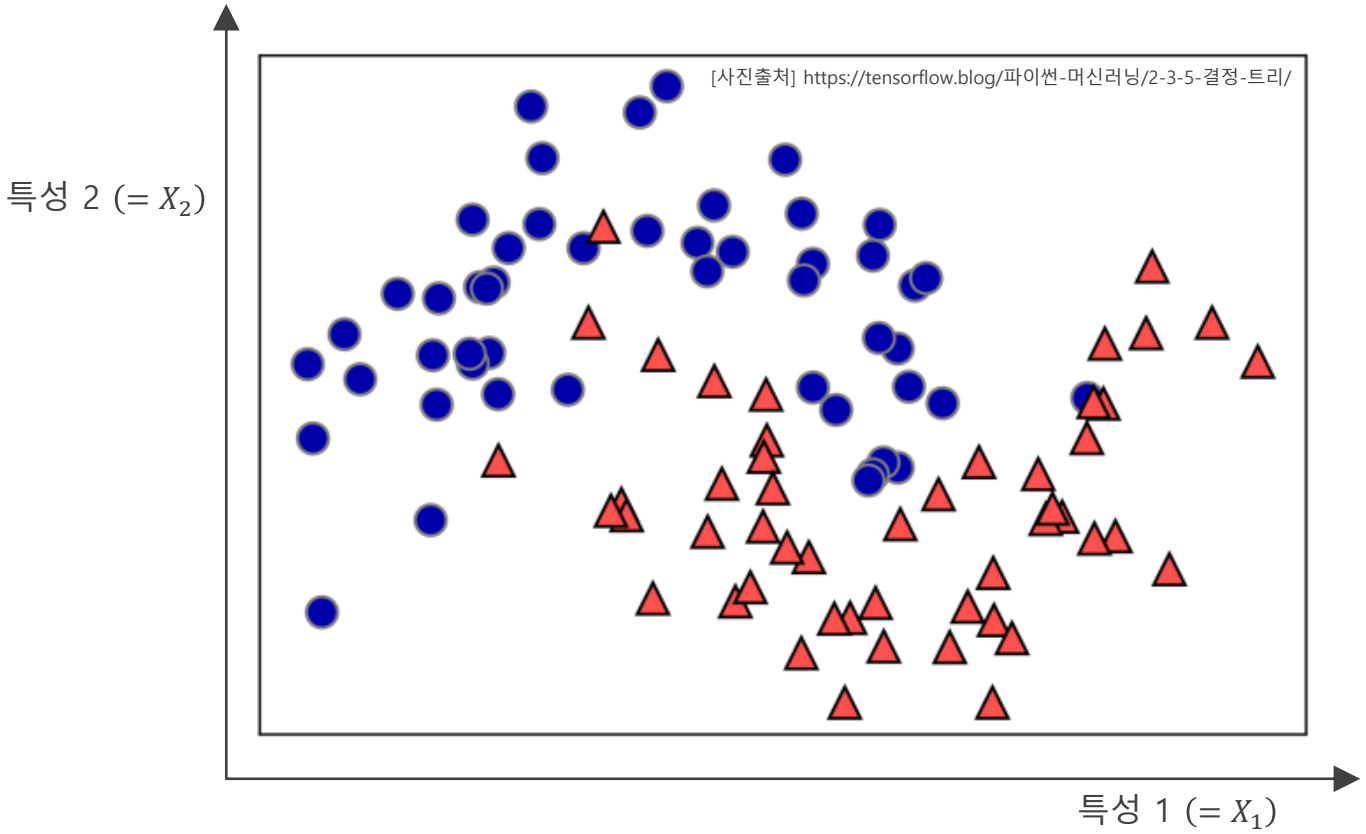

② 결정 트리 (Decision Tree) (4/8)

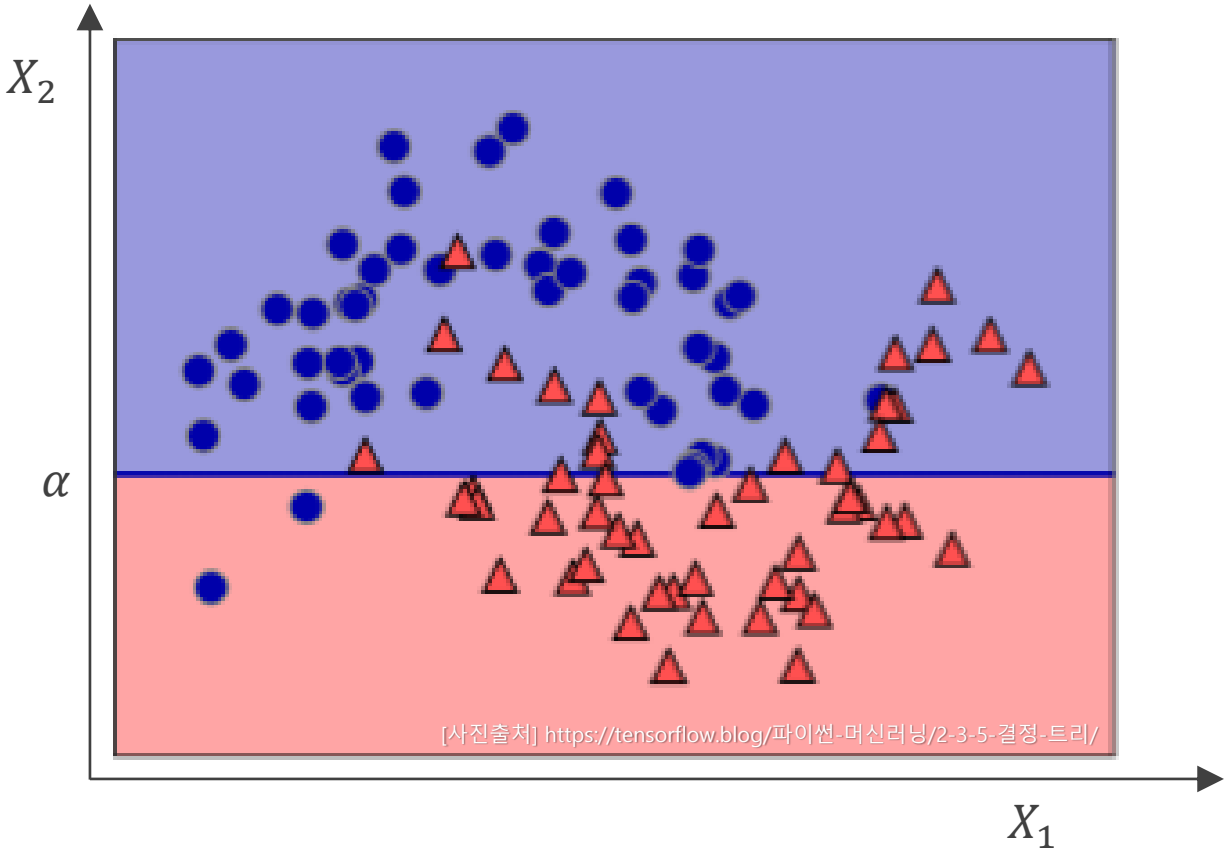

깊이 (Depth) = 1

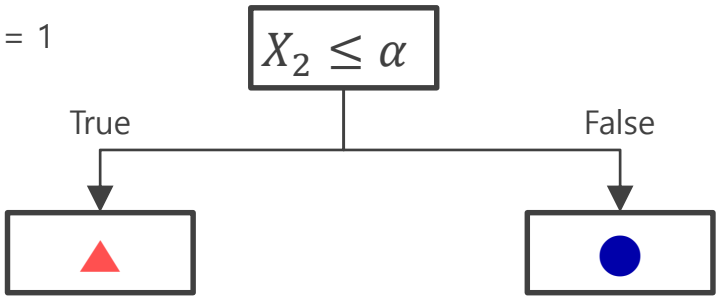

② 결정 트리 (Decision Tree) (5/8)

- ② 결정 트리 (Decision Tree) (5/8)

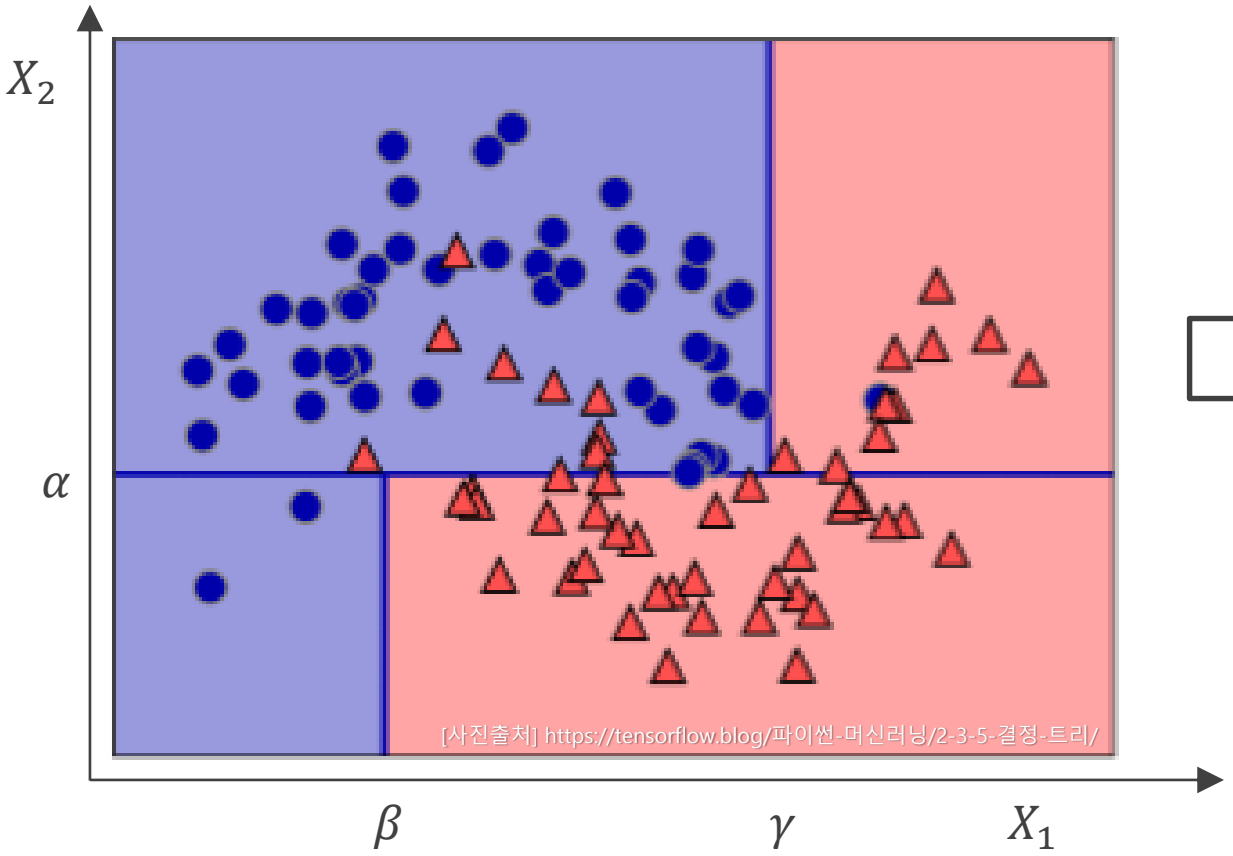

깊이 (Depth) = 2

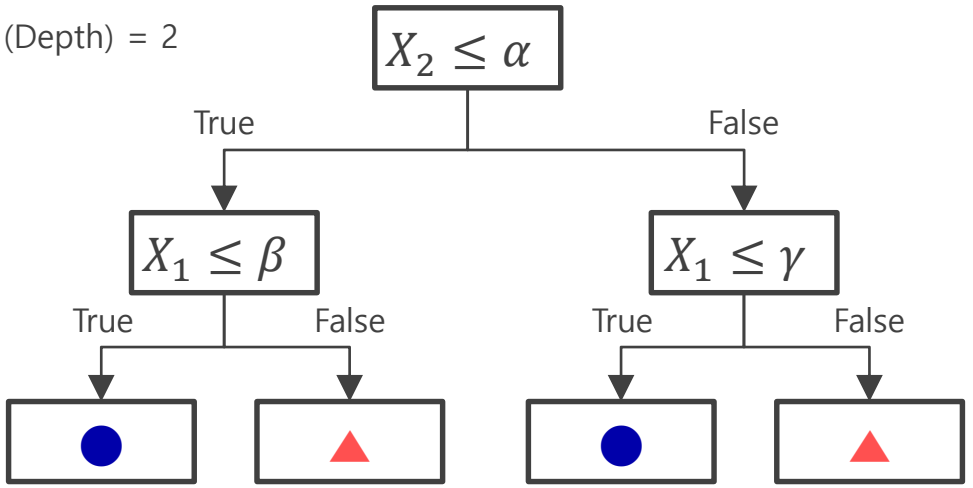

② 결정 트리 (Decision Tree) (6/8)

- ② 결정 트리 (Decision Tree) (6/8)

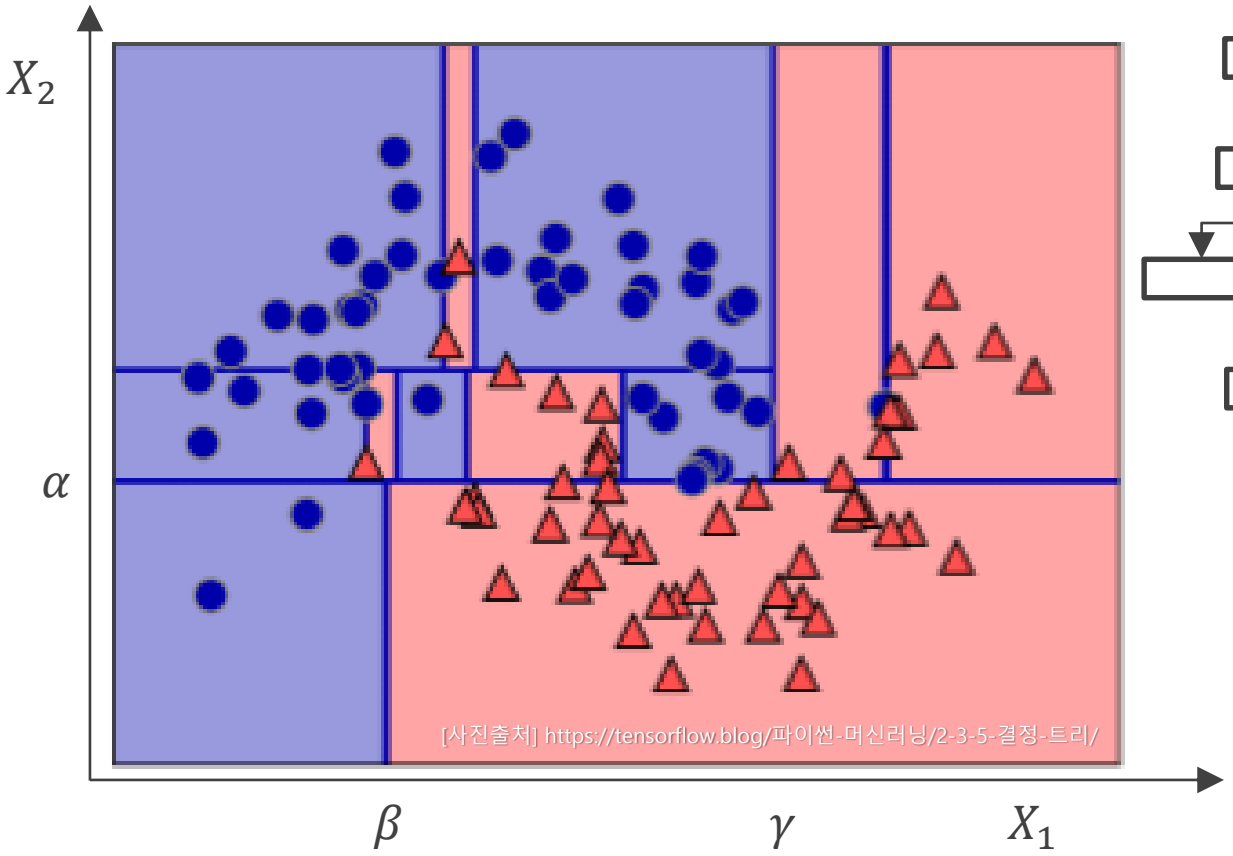

깊이 (Depth) = 9

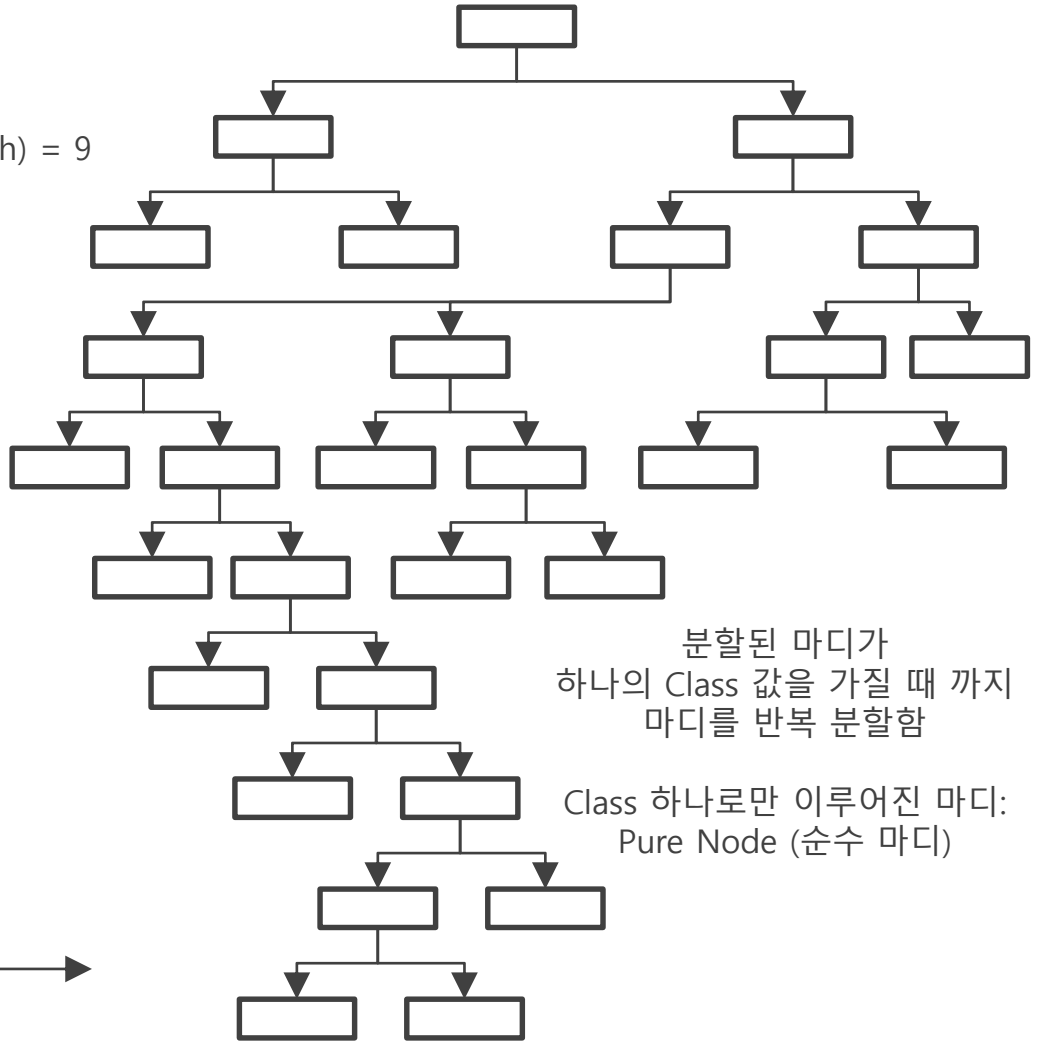

분할된 마디가
하나의 Class 값을 가질 때 까지
마디를 반복 분할함

Class 하나로만 이루어진 마디:
Pure Node (순수 마디)

② 결정 트리 (Decision Tree) (7/8)

- ② 결정 트리 (Decision Tree) (7/8)
  - 모든 끝 마디 (Terminal Node or Leaf Node)가 순수 마디 (Pure Node)가 될 때 까지, 가지 분할을 계속하게 되면 결정 트리 모델이 복잡해 지고 훈련 데이터 (Training Data)에 과대적합 (Overfitting)하게 됨
  - 해결 책으로 크게 2가지가 있음
    - 최대 깊이 (Depth)를 사전에 정하고 결정 트리 모델을 생성 (사전 가지치기, Pre-pruning)
    - 결정 트리 모델을 만들고 나서, 데이터 수가 적은 마디 (Node)를 제거 (사후 가지치기, Post-pruning)

② 결정 트리 (Decision Tree) (8/8)

- ② 결정 트리 (Decision Tree) (8/8)
  - 결정 트리는 분석 과정이 직관적이고 이해하기 쉬움
  - 인공신경망의 경우 분석 결과에 대한 설명이 어려운 블랙박스 모델인 반면, 결정 트리는 분석 과정을 눈으로도 관측할 수 있음
  - 그래서 결과에 대한 명확한 설명이 필요할 때 많이 사용함
  - k-NN 모델과 다르게 결정 트리 모델은 데이터의 Scale에 대한 전처리 (Pre-processing) 과정이 불필요

③ 랜덤 포레스트 (Random Forest) (1/3)

- **③ 랜덤 포레스트 (Random Forest) (1/3)**
  - 앙상블 (Ensemble) 학습 방법의 일종으로, 훈련 (Training) 과정에서 구성한 다수의 결정 트리 (Decision Tree)로부터 출력된 분류 결과로부터 다수결의 원칙에 따라 최종 분류 결과를 결정하는 방식으로 동작

나무 (Tree)가 모여서 숲 (Forest)을 이룬다

③ 랜덤 포레스트 (Random Forest) (2/3)

- **앙상블 (Ensemble) 학습 방법의 일종으로,**
  - 훈련 (Training) 과정에서 구성한 다수의 결정 트리 (Decision Tree)로부터 출력된 분류 결과로부터
    - 다수결의 원칙에 따라 최종 분류 결과를 결정하는 방식으로 동작

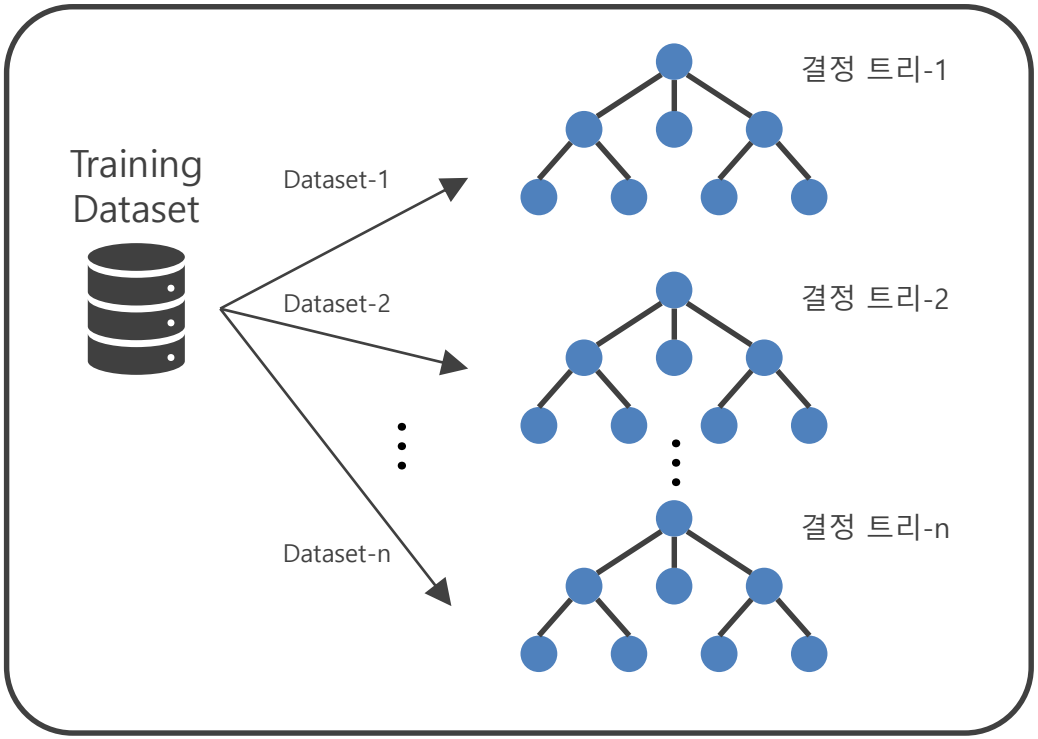

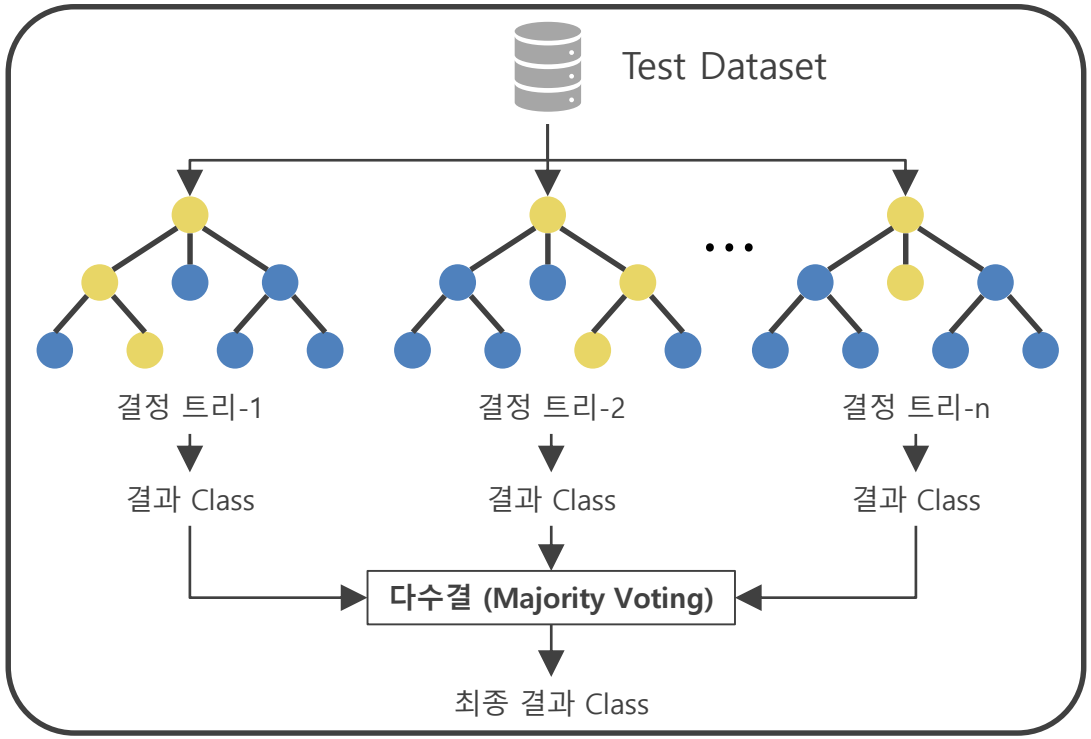

③ 랜덤 포레스트 (Random Forest) (3/3)

- **결정 트리 (Decision Tree)마다 서로 다른 가중치 (Weight)를 부여하여,**
  - 가중치가 큰 결정 트리로부터의 출력 분류 결과가 최종 분류 결과에 영향력을 더 많이 가할 수 있게 할 수도 있다

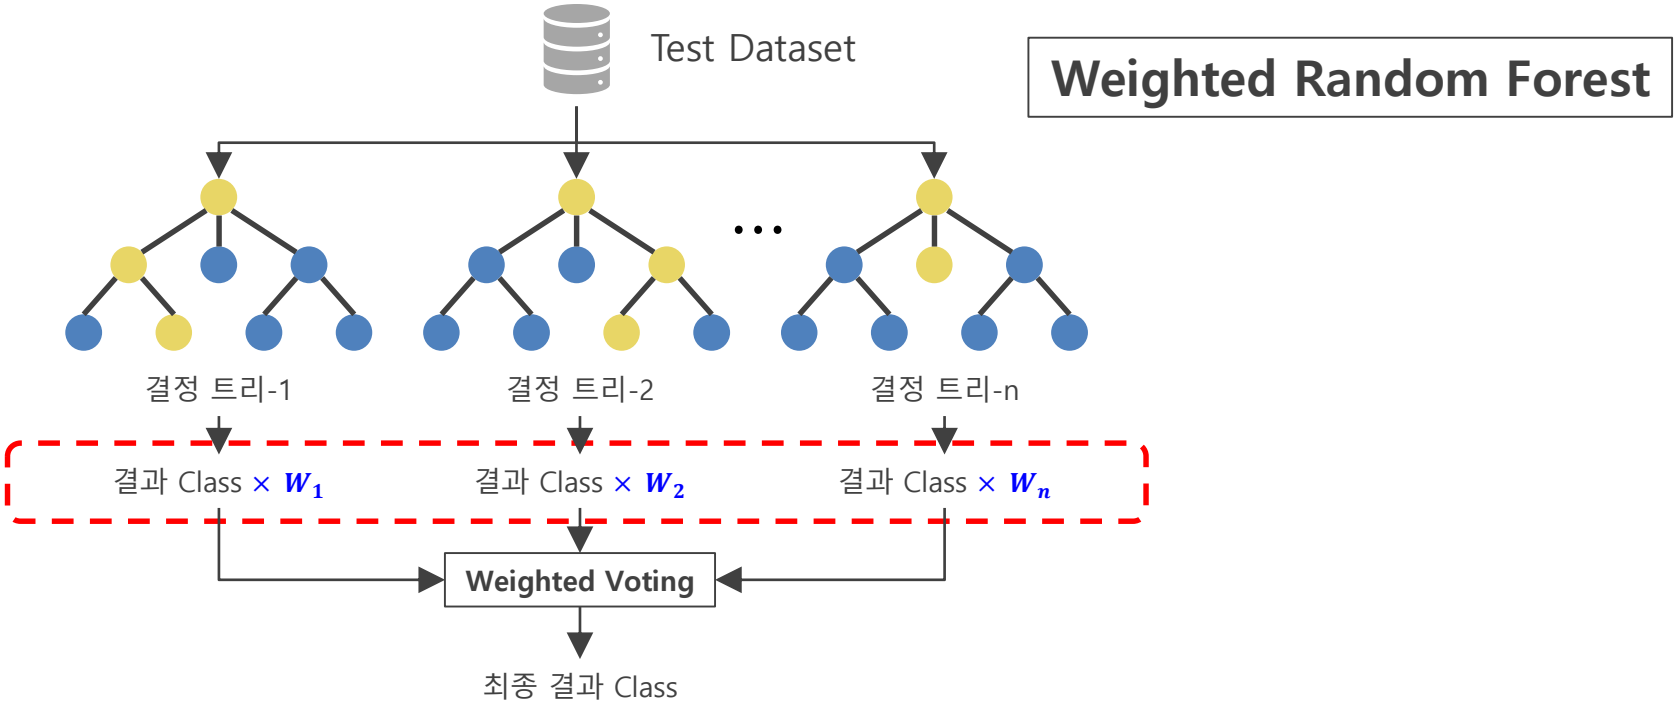

④ 서포트 벡터 머신 (Support Vector Machine, SVM) (1/12)

- ④ 서포트 벡터 머신 (Support Vector Machine, SVM) (1/12)
  - 주어진 데이터가 어느 그룹에 속하는지 분류하는 모델
  - 두 분류 (Classes) 사이의 여백을 의미하는 마진 (Margin)을 최대화하는 방향으로 데이터를 분류
  - SVM은 마진을 극대화하는 선을 찾아 분류하므로
    - 마진이 크면 클수록 새로운 데이터가 들어오더라도 잘 분류할 가능성이 높아짐
  - SVM은 사용 방법이 쉽고 예측 정확도가 높다는 장점
    - 하지만 모델 구축에 시간이 오래 걸리고 결과에 대한 설명력이 떨어지는 단점

④ 서포트 벡터 머신 (Support Vector Machine, SVM) (2/12)

●과 ▲는 학습 데이터 (Training Data)

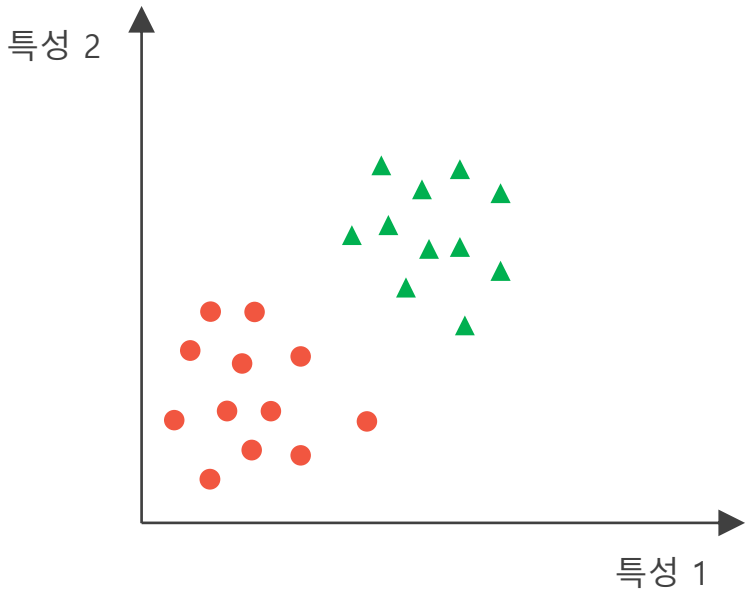

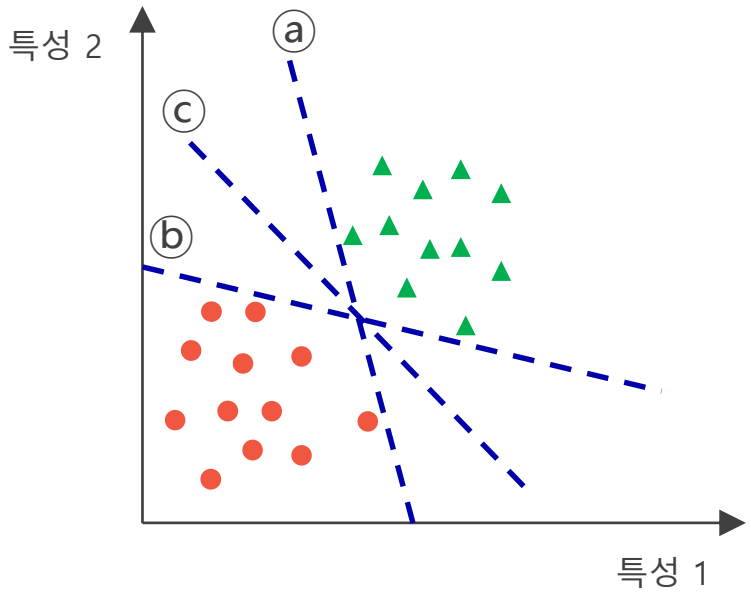

ⓐ, ⓑ, ⓒ 모두 ●과 ▲를 잘 분류하고 있다

④ 서포트 벡터 머신 (Support Vector Machine, SVM) (3/12)

시험 데이터 ★이 주어졌다.

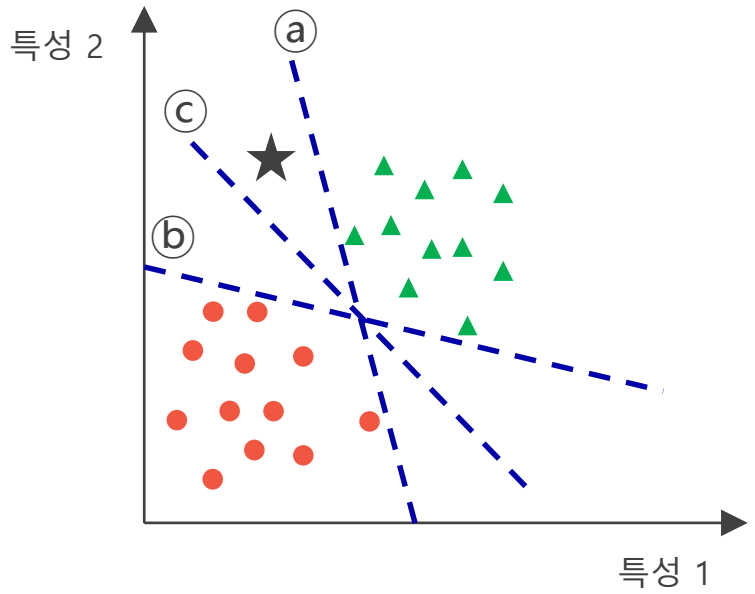

분류기 (Classifier) ⓐ를 살펴보자.

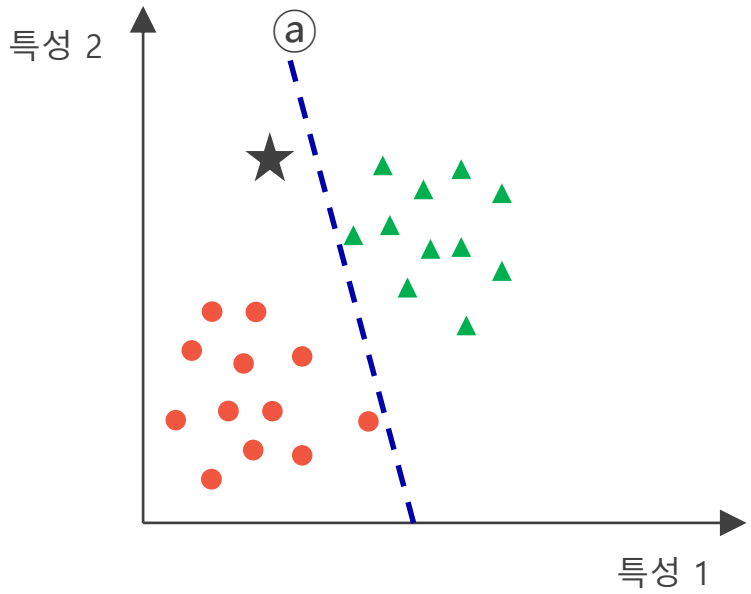

ⓐ는 ★을 ●로 분류한다

④ 서포트 벡터 머신 (Support Vector Machine, SVM) (4/12)

분류기 (Classifier) ⓑ를 살펴보자.

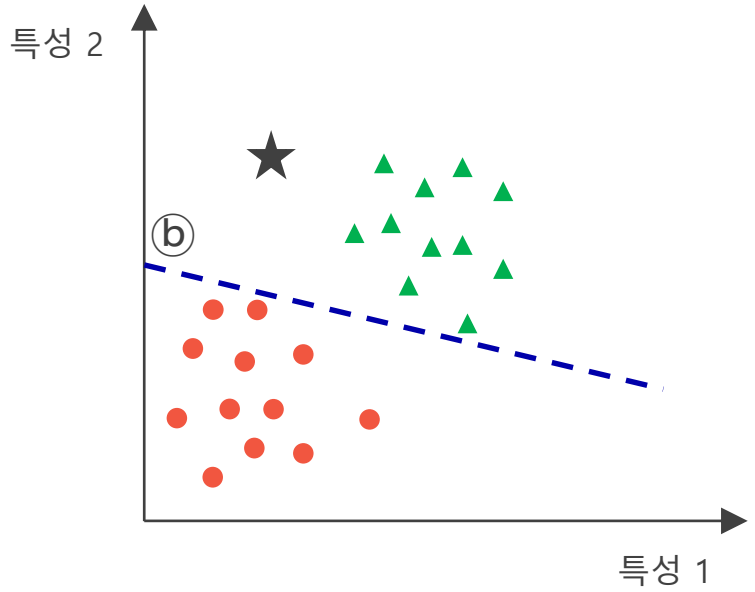

ⓑ는 ★을 ▲로 분류한다

분류기 (Classifier) ⓒ를 살펴보자.

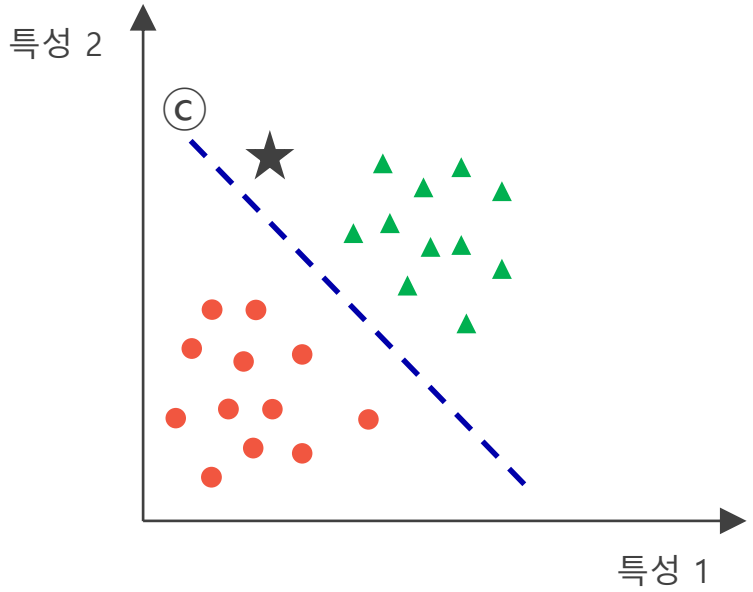

ⓒ는 ★을 ▲로 분류한다

④ 서포트 벡터 머신 (Support Vector Machine, SVM) (5/12)

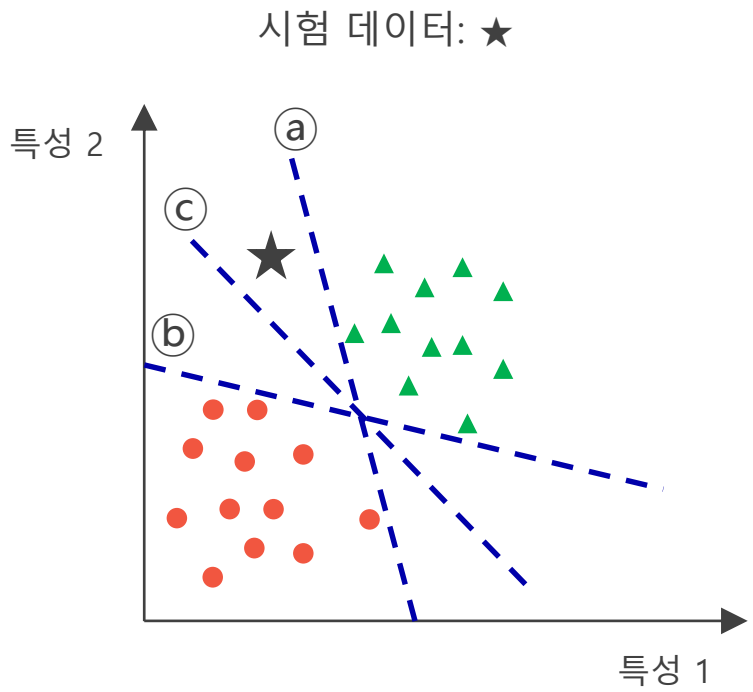

ⓐ는 ★을 ●로 분류한다

ⓑ는 ★을 ▲로 분류한다

ⓒ는 ★을 ▲로 분류한다

ⓐ, ⓑ, ⓒ 중에 어떤 모델이 더 우수한 걸까?

④ 서포트 벡터 머신 (Support Vector Machine, SVM) (6/12)

New 시험 데이터: ♣

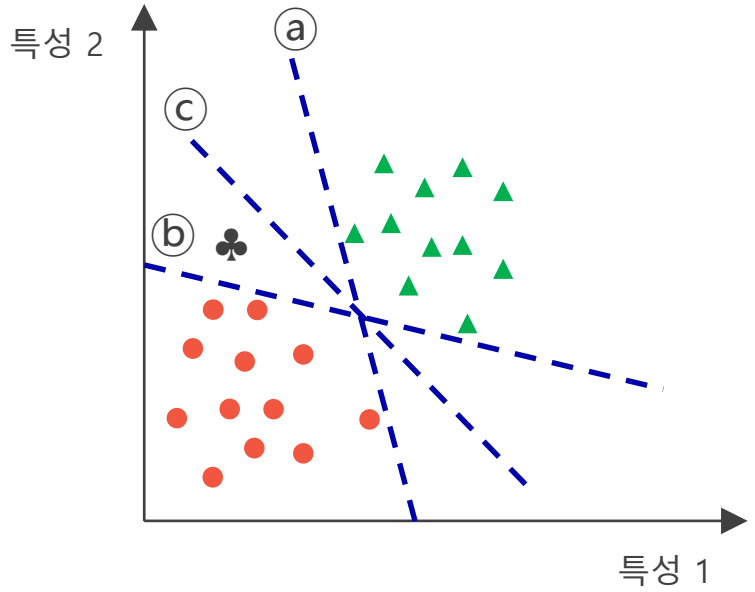

분류기 (Classifier) ⓐ를 살펴보자.

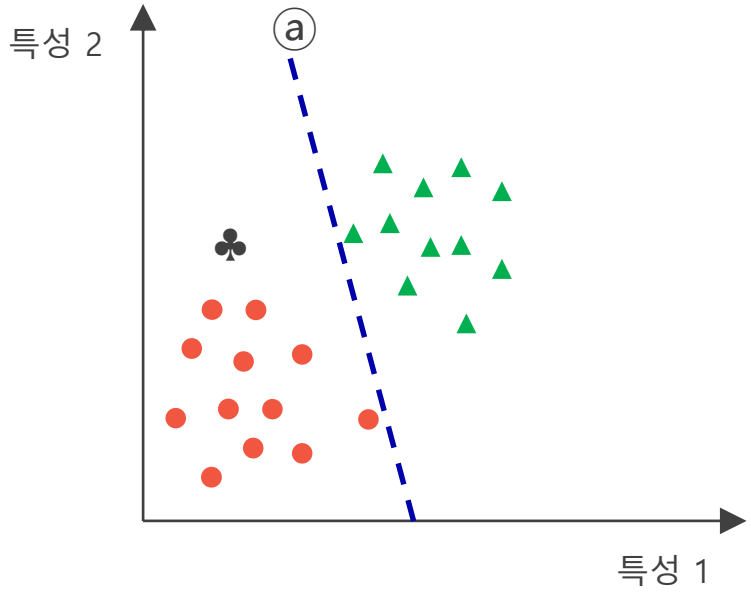

ⓐ는 ♣을 ●로 분류한다

④ 서포트 벡터 머신 (Support Vector Machine, SVM) (7/12)

분류기 (Classifier) ⓑ를 살펴보자.

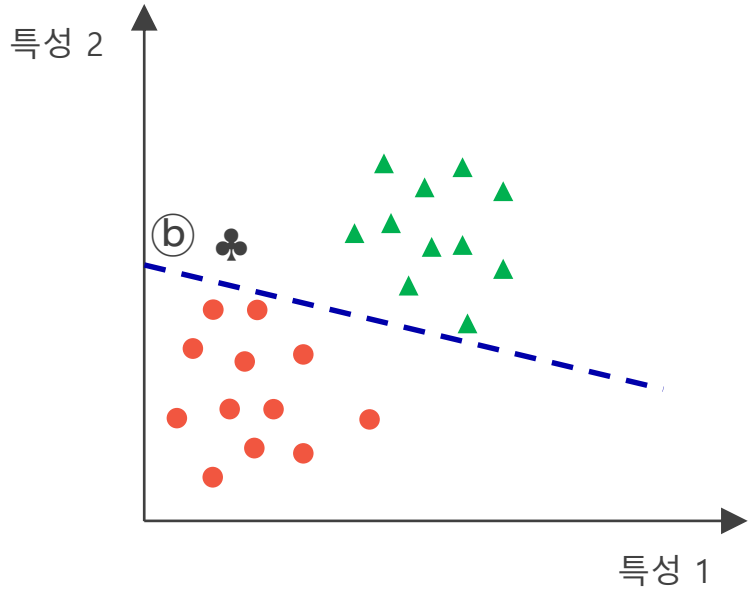

ⓑ는 ♣을 ▲로 분류한다

분류기 (Classifier) ⓒ를 살펴보자.

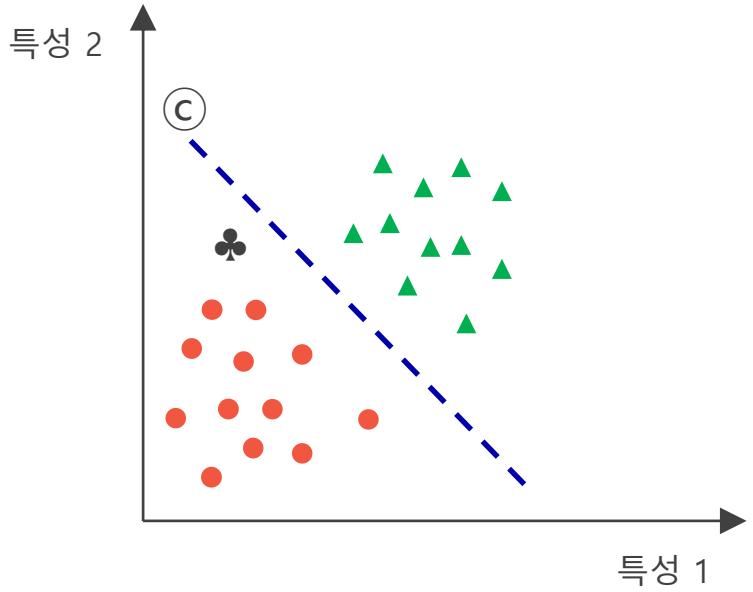

ⓒ는 ♣을 ●로 분류한다

④ 서포트 벡터 머신 (Support Vector Machine, SVM) (8/12)

New 시험 데이터: ♣

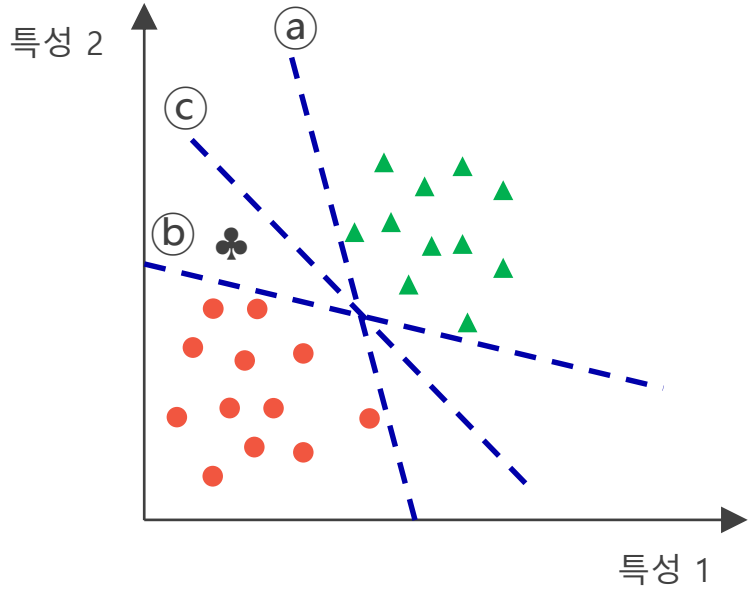

ⓐ는 ♣을 ●로 분류한다

ⓑ는 ♣을 ▲로 분류한다

ⓒ는 ♣을 ●로 분류한다

ⓐ, ⓑ, ⓒ 중에 어떤 모델이 더 우수한 걸까?

④ 서포트 벡터 머신 (Support Vector Machine, SVM) (9/12)

시험 데이터: ★, ♣

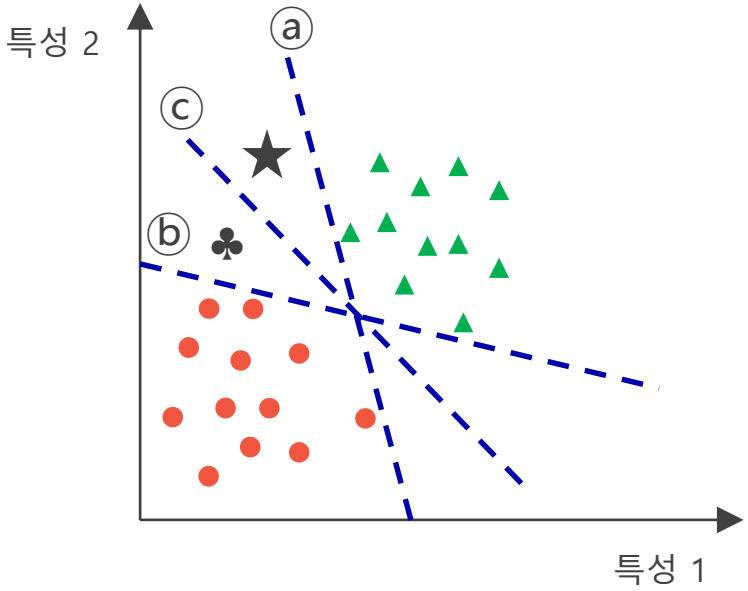

분류기 (Classifier)	시험 데이터 ★	시험 데이터 ♣	정확도
ⓐ	● (오분류)	●	50%
ⓑ	▲	▲ (오분류)	50%
ⓒ	▲	●	100%

ⓒ가 가장 우수한 모델인 것 같다!

④ 서포트 벡터 머신 (Support Vector Machine, SVM) (10/12)

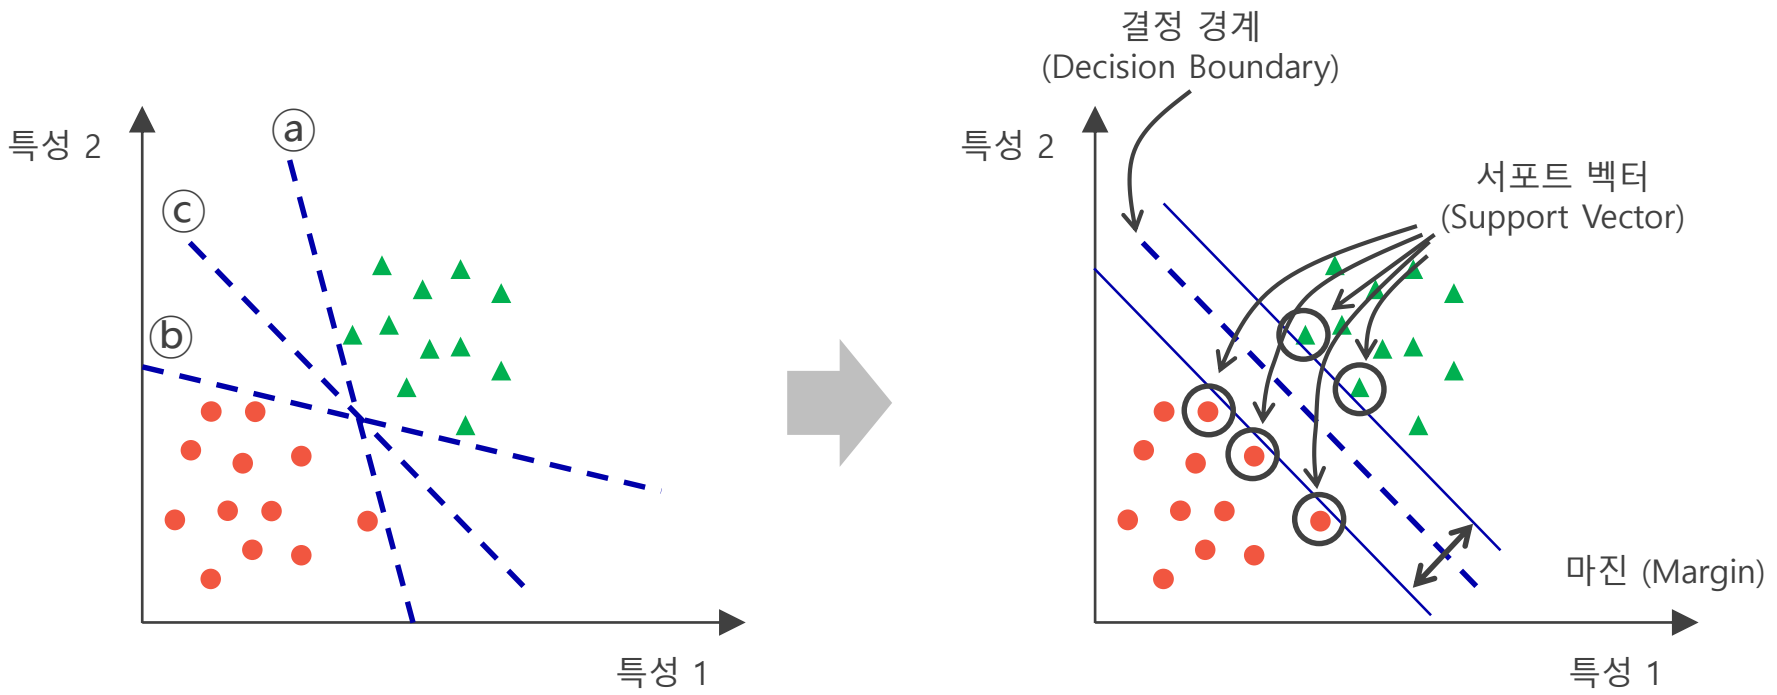

- 결정 경계 (Decision Boundary): 분류를 위한 기준선
- 서포트 벡터 (Support Vector): 결정 경계와 가장 가까운 위치에 있는 데이터
- 마진 (Margin): 결정 경계와 서포트 벡터 사이의 거리

④ 서포트 벡터 머신 (Support Vector Machine, SVM) (11/12)

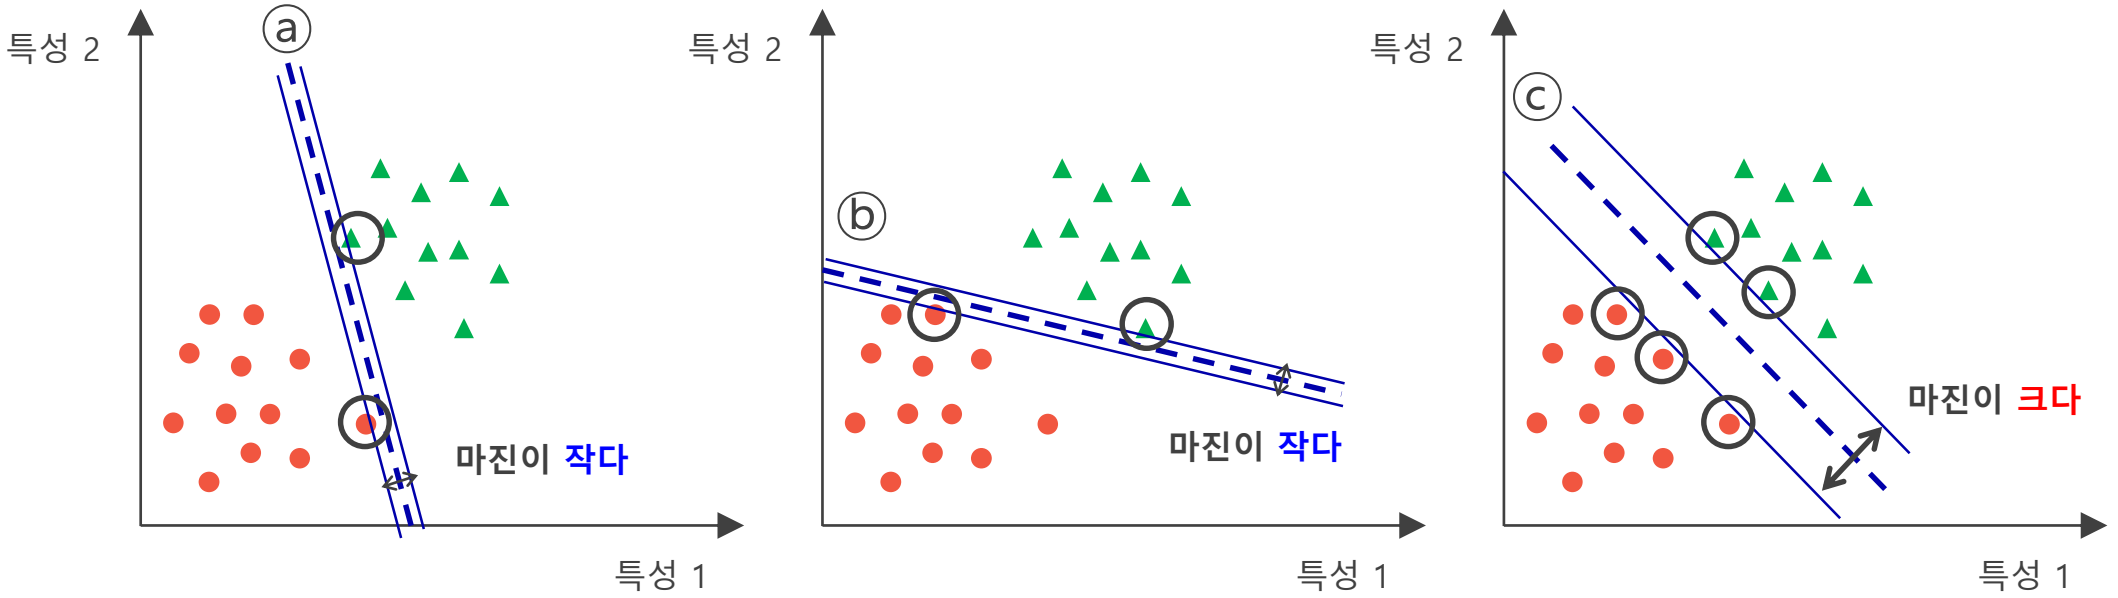

마진 (Margin)을 극대화 하는 선을 찾으면

새로운 데이터 (시험 데이터)가 들어오더라도 잘 분류 하겠구나!

④ 서포트 벡터 머신 (Support Vector Machine, SVM) (12/12)

- 주어진 데이터가 어느 그룹에 속하는지 분류하는 모델
- 두 분류 (Classes) 사이의 여백을 의미하는 마진 (Margin)을 최대화하는 방향으로 데이터를 분류
- SVM은 마진을 극대화하는 선을 찾아 분류하므로 마진이 크면 클수록 새로운 데이터가 들어오더라도 잘 분류할 가능성이 높아짐
- SVM은 사용 방법이 쉽고 예측 정확도가 높다는 장점
- 하지만 모델 구축에 시간이 오래 걸리고 결과에 대한 설명력이 떨어지는 단점

⑤ 앙상블 학습 (Ensemble Learning)

- **학습 알고리즘들을 따로 쓰는 경우에 비해 더 좋은 성능을 얻기 위해 다수의 학습 알고리즘을 사용하는 방법**

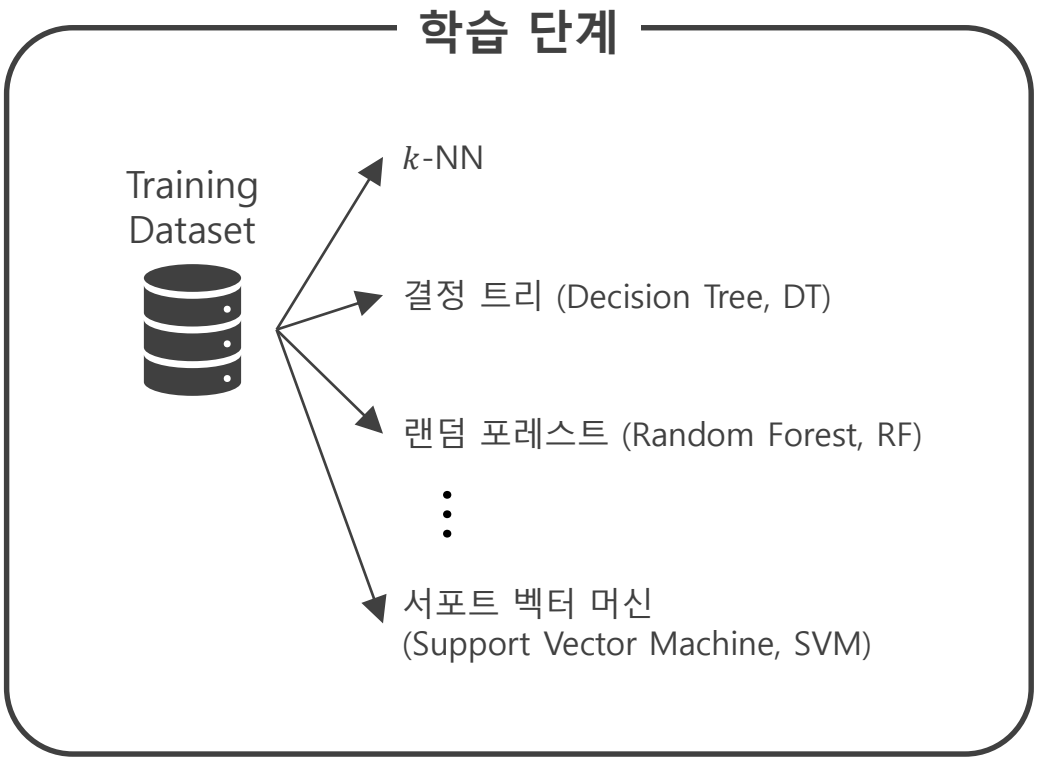

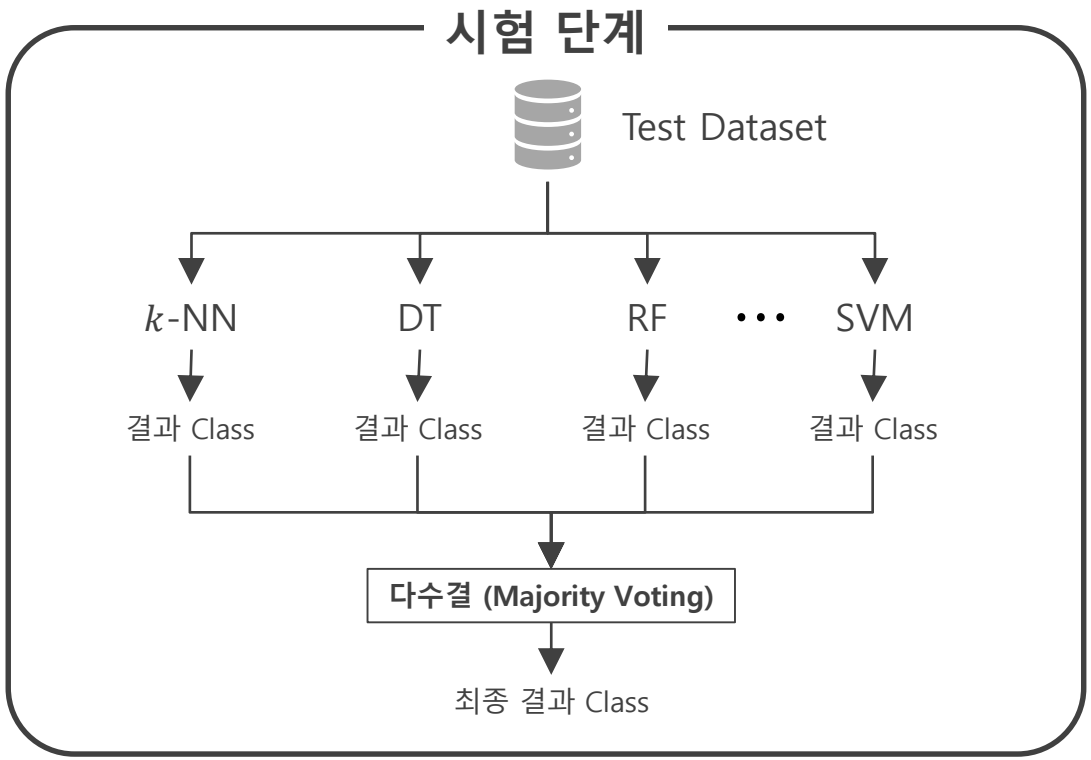

분류 문제를 다루는 지도학습 알고리즘의 우수성을 평가하는 방법

- **혼동 행렬 (Confusion Matrix)**
- **분류 정확도 (Accuracy)**

이진 분류 (Binary Classification) 문제를 가정

혼동 행렬 (Confusion Matrix)라고 부릅니다

		학습 알고리즘의 답 Class 1	학습 알고리즘의 답 Class 2
실제 정답	Class 1	A (30)	B (20)
	Class 2	C (10)	D (40)

$$\text{Accuracy} = \frac{A+B}{A+B+C+D} = \frac{30+40}{30+20+10+40} = \frac{70}{100} = 0.7$$

$$\text{Accuracy}\ (\%) = 0.7 \times 100\ (\%) = 70\%$$

일반적으로 분류 정확도 (Accuracy)를 이용해서 학습 알고리즘의 우수성을 평가합니다

AI Experts
Who Lead
The Future

04

지도학습의 회귀 알고리즘

다음 자료를 기반으로 제작
난생처음 인공지능 입문 (출판사: 한빛아카데미)

회귀와 분류

- **분류 (Classification)**
  - 어떤 입력 데이터가 들어오더라도 학습에 사용한 레이블 (Label)중 하나로 결과값을 결정
  - 레이블 (Label)이 이산적인 (Discrete) 경우 (즉, [0, 1, 2, 3, …]와 같이 유한한 경우)

- **회귀 (Regression)**
  - 입력 데이터에 대한 결과값으로 학습에 사용한 레이블 이외의 값이 나올 수 있음
  - 레이블 (Label)이 실수인 경우
    - 키 (Height) 정보가 주어졌을 때, 몸무게를 예측
    - 공부한 시간 정보가 주어졌을 때, 시험 성적 예측
    - 커피를 몇 잔 마셨는지에 대한 정보가 주어졌을 때, 수면 시간 예측

회귀 개요

- **회귀 (Regression)**
  - **19세기, 통계학자이자 인류학자인 프랜시스 골턴 (Francis Galton)이 처음 사용**

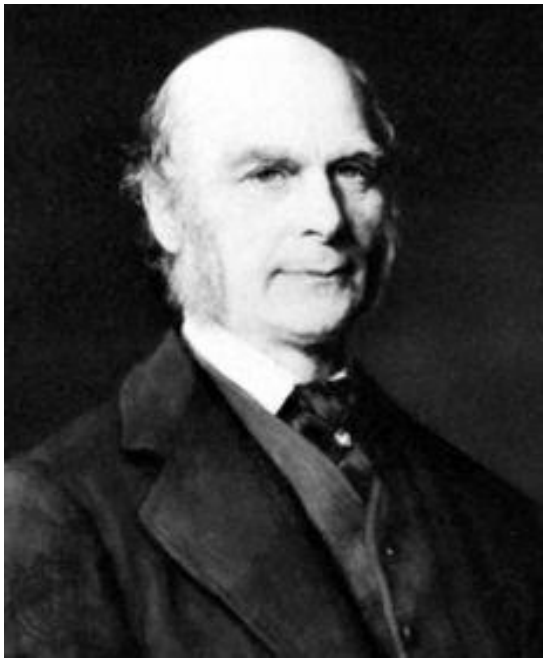

[사진출처] https://en.wikipedia.org/wiki/Francis_Galton

프랜시스 골턴

- 아버지와 자식의 키를 분석함
- 사람의 키 (Height)는 세대를 거듭할 수록 평균에 가까워지는 경향이 있다는 것을 발견
- 키가 큰 아버지의 자식은 아버지보다 키가 작고,
  키가 작은 아버지의 자식은 아버지보다 키가 크다
- 즉, 세대를 거듭할 수록 큰 키는 작아지고, 작은 키는 커지고 평균에 수렴한다
- 이를 프랜시스 골턴은 "평균으로 돌아간다 (=회귀)"라고 표현함

변수 사이의 관계를 분석하는 방법을
역사적인 이유 때문에 "회귀 (Regression)" 라고 부르게 되었다!

회귀 (Regression) 문제를 해결하기 위한 기법

- ① k-최근접 이웃 (k-Nearest Neighbors, k-NN)
- ② 결정 트리 (Decision Tree)
- ③ 선형 회귀 (Linear Regression)
- ④ 다항 회귀 (Polynomial Regression)

① k-최근접 이웃 (k-Nearest Neighbors, k-NN) (1/2)

- 시험 데이터가 주어졌을 때, 시험 데이터로부터 거리가 가장 가까운 k개의 학습 데이터의 Labels의 평균 값을 시험 데이터의 Label 값으로 결정하는 알고리즘
- 예를 들어,
  - $k = 3$일 때, 시험 데이터 ★에 대한 결과 값은 가장 가까운 3개의 학습 데이터의 평균 값 120으로 결정

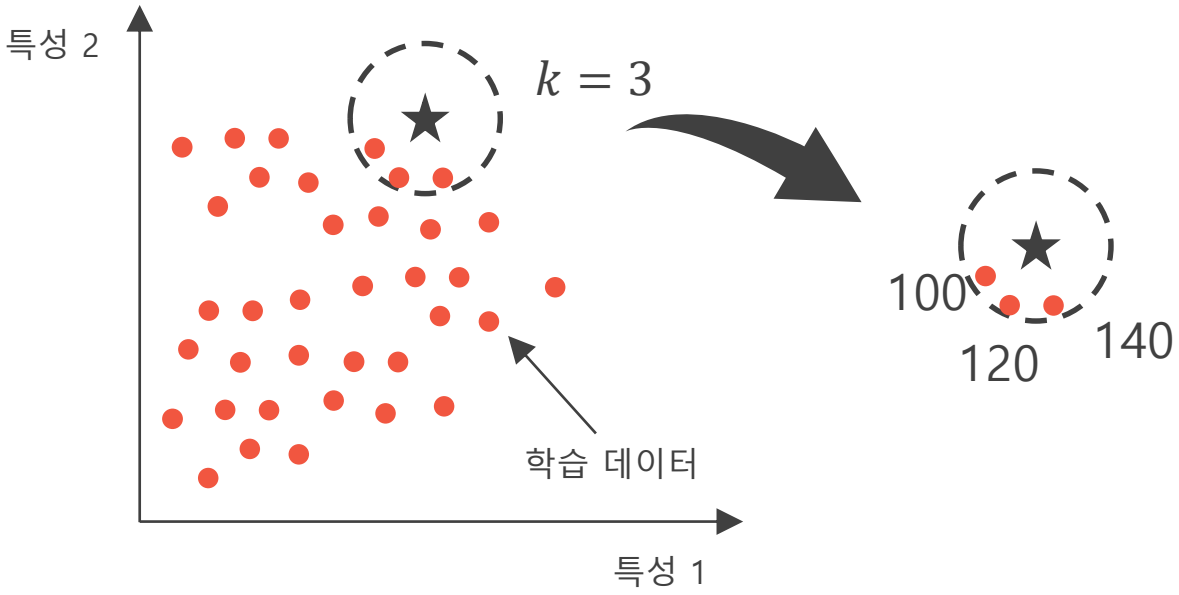

$$\frac{100 + 120 + 140}{3} = \frac{360}{3} = 120$$

① k-최근접 이웃 (k-Nearest Neighbors, k-NN) (2/2)

- **가중 회귀 (Weighted Regression)**
  - 시험 데이터가 주어졌을 때, 시험 데이터로부터 거리가 가장 가까운 k개의 학습 데이터를 찾음
  - 단순히 학습데이터의 Labels의 평균 값을 계산하는 것이 아니라,
    - 시험 데이터와 학습 데이터 사이의 거리를 고려하여 가중합으로 Label 값으로 결정
- **예를 들어,**
  - $k = 3$일 때, 시험 데이터 ★에 대한 가중 회귀 결과값은 115.4로 결정

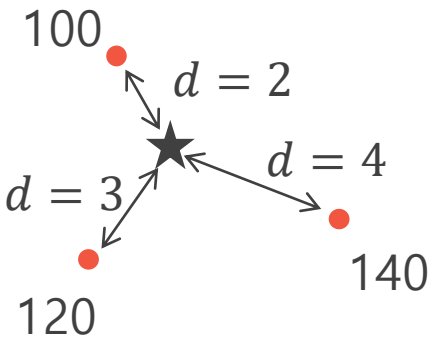

시험 데이터와 멀리 떨어져 있는
학습 데이터일수록 영향력을 줄이겠다!

Labels의 평균 값: $\frac{100 + 120 + 140}{3} = \frac{360}{3} = 120$

가중 회귀 결과값: $\frac{\frac{100}{2} + \frac{120}{3} + \frac{140}{4}}{\frac{1}{2} + \frac{1}{3} + \frac{1}{4}} = \frac{\frac{600 + 480 + 420}{12}}{\frac{13}{12}} = \frac{1500}{13} \approx 115.4$

② 결정 트리 (Decision Tree) (1/2)

- **학습 데이터로부터 결정 트리를 생성하고, 각 끝 마디 (Terminal Node or Leaf Node)에서 해당 영역의 평균 값을 계산**

Y: 해당 영역의 평균 값

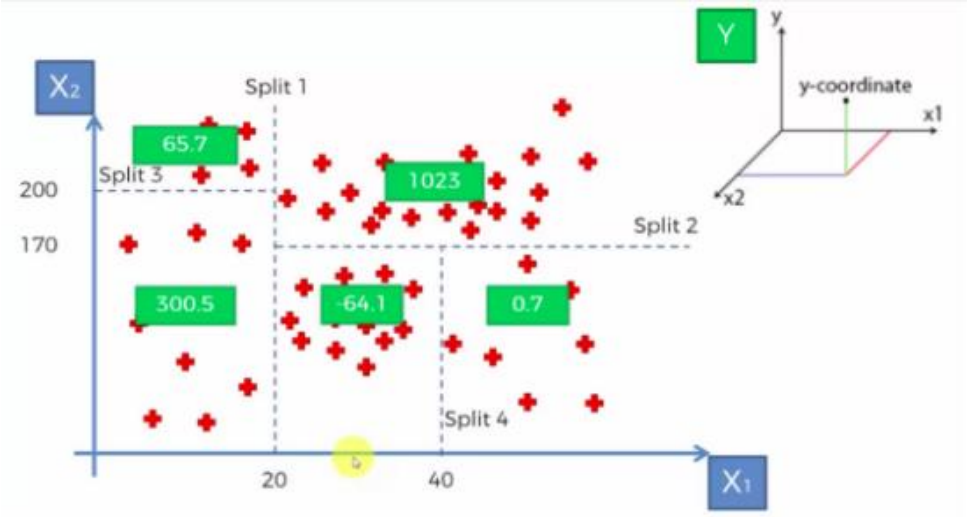

[사진출처] https://riverzayden.tistory.com/6

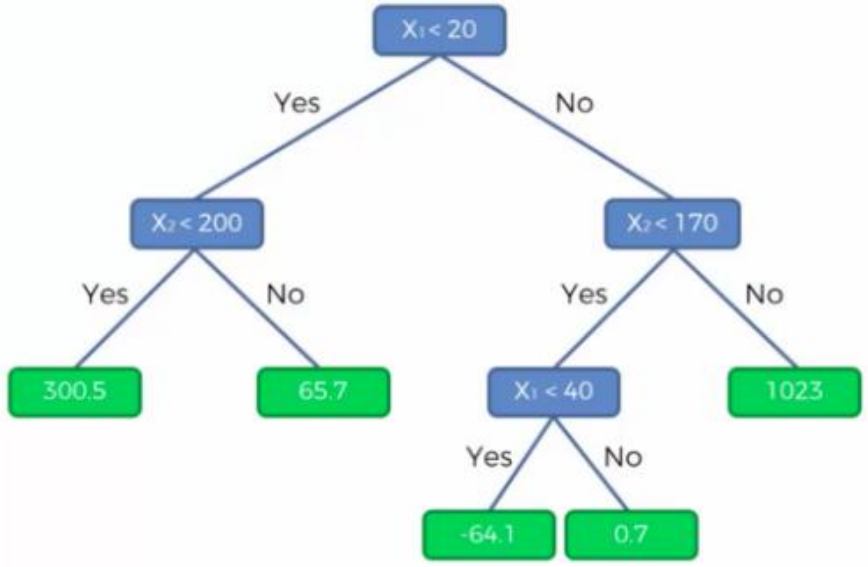

② 결정 트리 (Decision Tree) (2/2)

- **시험 데이터 (Test Data)가 주어졌을 때, 시험 데이터가 속한 영역의 평균 값으로 회귀 결과값을 결정하는 알고리즘**

Y: 해당 영역의 평균 값

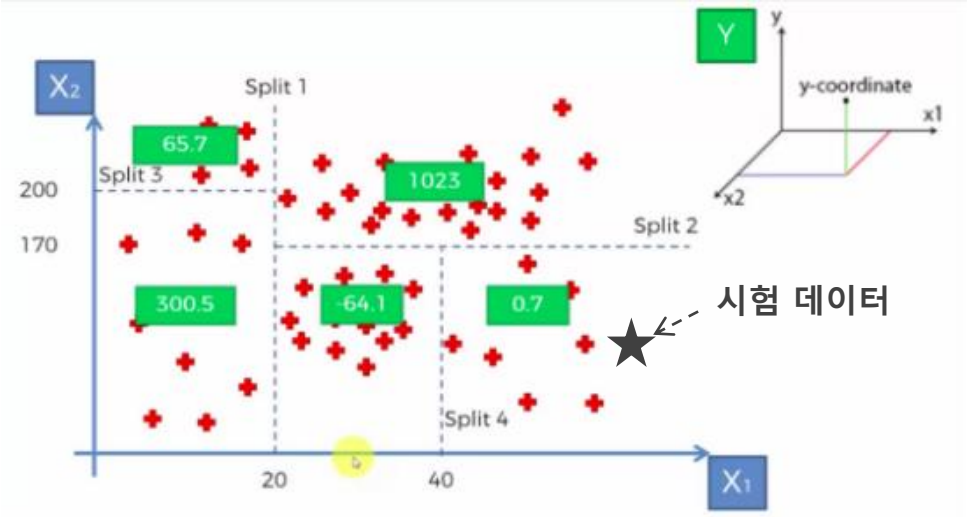

[사진출처] https://riverzayden.tistory.com/6

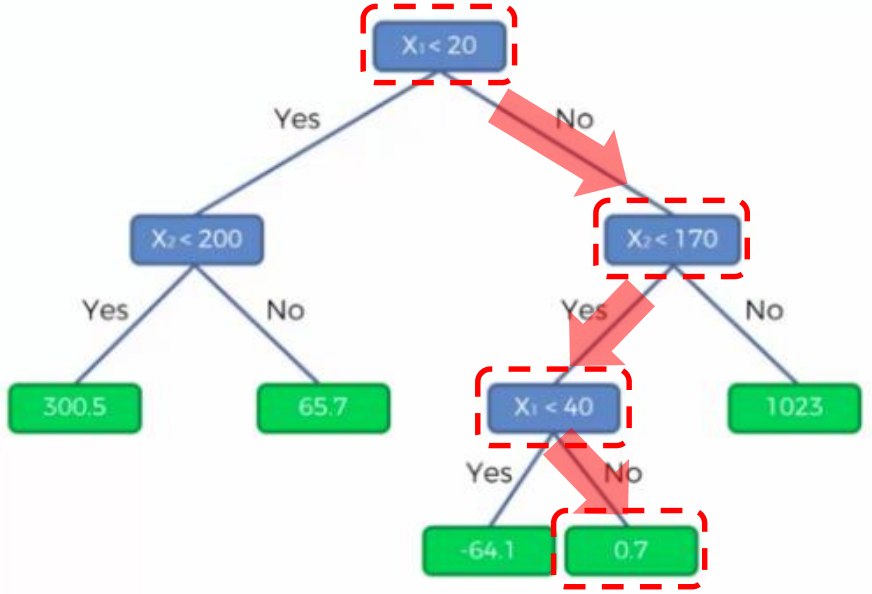

시험 데이터 ★의 회귀 결과값: 0.7

③ 선형 회귀 (Linear Regression) (1/4)

- **학습 데이터 (Training Data)로부터 종속 변수 y와 한 개 이상의 독립 변수 x와의 선형 상관 관계를 모델링하는 방법**
  (쉽게 이해하면, 학습 데이터를 잘 표현하는 직선 하나를 찾아내겠다는 의미)

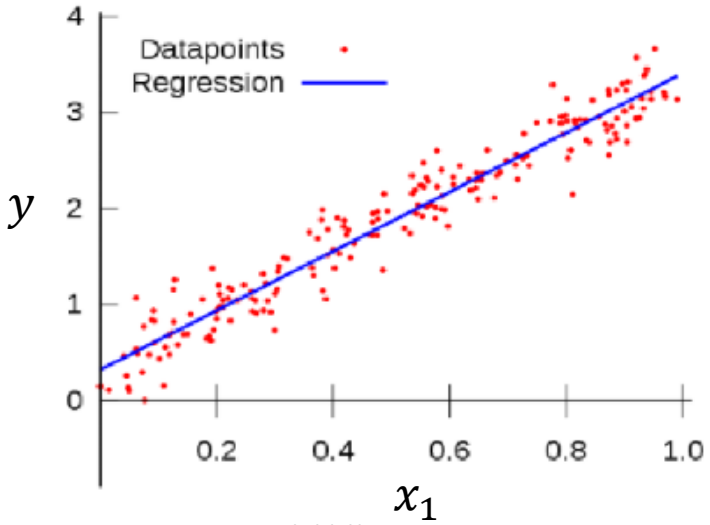

[사진출처] https://bangu4.tistory.com/100

빨간색 점들이 학습 데이터이고,

이 데이터들을 잘 표현하는 파란색 직선을

찾아내는 것이 "선형 회귀"가 하는 역할임

③ 선형 회귀 (Linear Regression) (2/4)

- **독립 변수 x의 개수에 따라 선형 회귀는 아래와 같이 분류됨**
  - 단순 선형 회귀 (Simple Linear Regression): 독립 변수 x의 개수가 1개
  - 다중 선형 회귀 (Multiple Linear Regression): 독립 변수 x의 개수가 2개 이상

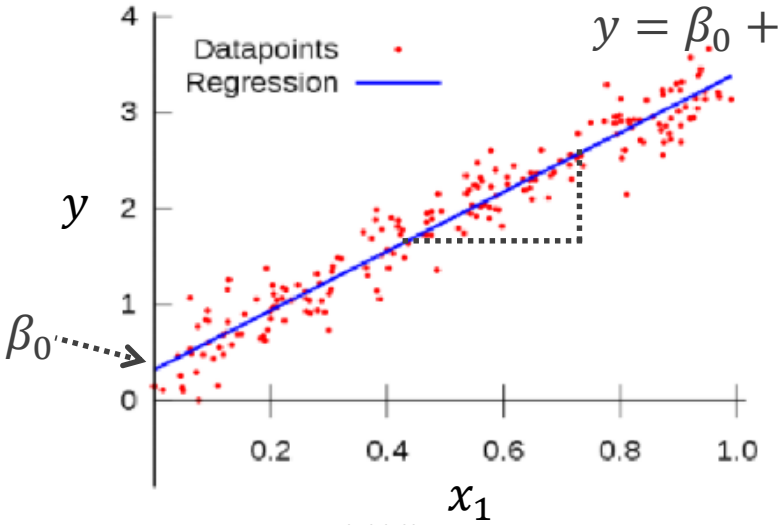

[사진출처] https://bangu4.tistory.com/100

$$y = \beta_0 + \beta_1 \times x_1$$

왼쪽 예제는 독립 변수의 개수가 1개인 경우임

$$y = \beta_0 + \beta_1 \times x_1$$

위 직선에서 기울기 $(= \beta_1)$ 값과 y절편 $(= \beta_0)$ 값을 찾는 것이 선형 회귀 알고리즘에서 수행하는 동작

③ 선형 회귀 (Linear Regression) (3/4)

- **독립 변수 x의 개수에 따라 선형 회귀는 아래와 같이 분류됨**
  - 단순 선형 회귀 (Simple Linear Regression): 독립 변수 x의 개수가 1개
  - 다중 선형 회귀 (Multiple Linear Regression): 독립 변수 x의 개수가 2개 이상

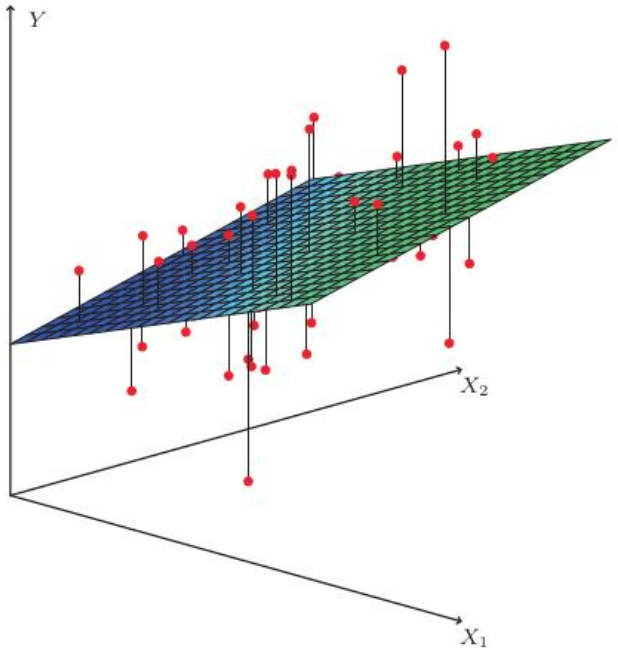

[사진출처] https://p829911.github.io/2020/01/16/3.2.1/

왼쪽 예제는 독립 변수의 개수가 2개 (x_1, x_2)인 경우임

$$y = \beta_0 + \beta_1 \times x_1 + \beta_2 \times x_2$$

선형 회귀 알고리즘 수행을 통해서,

학습 데이터를 가장 잘 표현 하는 β_0, β_1, β_2 값을 찾아냄

③ 선형 회귀 (Linear Regression) (4/4)

- **독립 변수 x의 개수에 따라 선형 회귀는 아래와 같이 분류됨**
  - **단순 선형 회귀 (Simple Linear Regression): 독립 변수 x의 개수가 1개**
  - **다중 선형 회귀 (Multiple Linear Regression): 독립 변수 x의 개수가 2개 이상**

독립 변수의 개수가 3개를 넘어가게 되면, 시각적으로 표현하기가 어려워 짐

$$y = \beta_0 + \beta_1 \times x_1 + \beta_2 \times x_2 + \cdots + \beta_i \times x_i + \cdots + \beta_n \times x_n$$

$$= \beta_0 + \sum_{i=1}^{n} (\beta_i \times x_i)$$

이 경우에도 선형 회귀 알고리즘 수행을 통해서,

학습 데이터를 가장 잘 표현 하는 $\beta_0, \beta_1, \cdots, \beta_n$ 값을 찾아냄

④ 다항 회귀 (Polynomial Regression) (1/2)

- **선형 회귀의 단점**
  - 학습 데이터 내, 종속 변수 y와 독립 변수 x 사이의 상관 관계가 선형이 아닐 수 있다

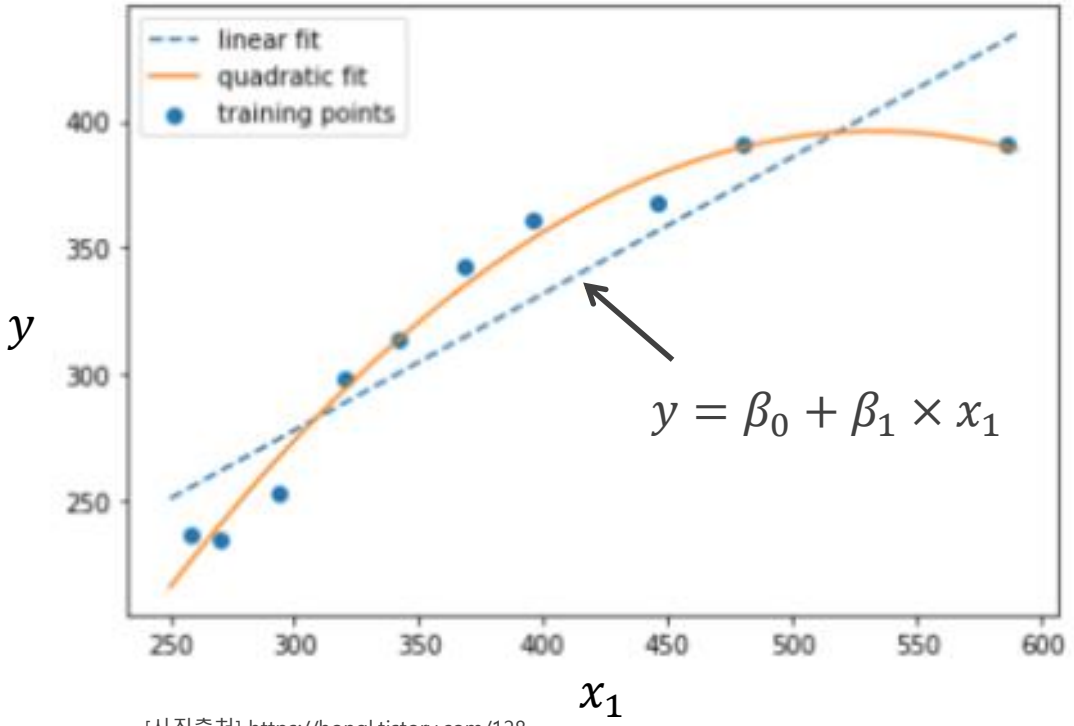

[사진출처] https://hongl.tistory.com/128

학습 데이터 ●가 선형 회귀 모형 (점선)으로 잘 표현되지 않고 있다 (오차가 크다)

오히려 주황색 실선이 학습 데이터 ●를 잘 표현하고 있다 (오차가 작다)

④ 다항 회귀 (Polynomial Regression) (2/2)

- 각 독립 변수 x에 대한 고차원의 다항식을 이용하여 종속 변수 y의 관계를 비선형적 (Non-linear)으로 모델링하는 방법

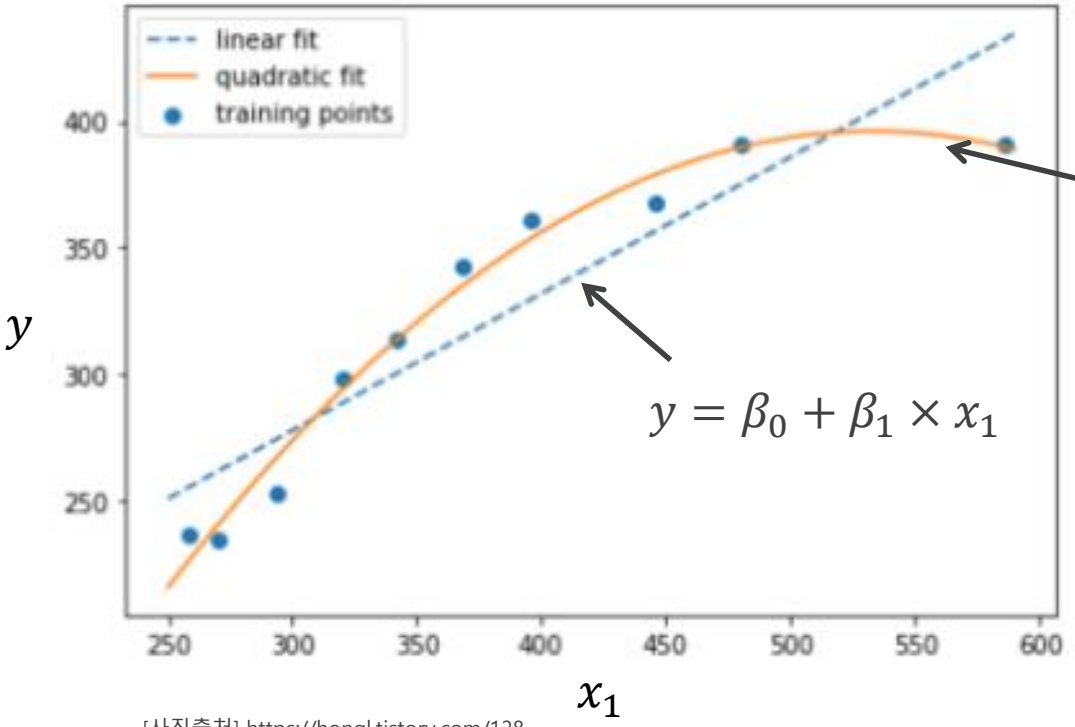

[사진출처] https://hongl.tistory.com/128

왼쪽 예제는 독립 변수의 개수가 1개인 경우임

$$y = \beta_0 + \beta_1 \times x_1 + \beta_2 \times x_1^2 + \cdots + \beta_n \times x_1^n$$

다항 회귀 알고리즘 수행을 통해서,

학습 데이터를 가장 잘 표현 하는

$\beta_0, \beta_1, \cdots, \beta_n$ 값을 찾아냄